

فصل ششم: یادگیری بیزی

استدلال بیز روشی احتمالی برای استنتاج ارائه می‌کند. این روش بر اساس این فرض است که کمیت‌های مورد نظر از توزیع‌های احتمال پیروی می‌کنند و تصمیم‌گیری بهینه را می‌توان با استدلال بر این توزیع‌های احتمال و داده‌های مشاهده شده انجام داد. اهمیت این روش در یادگیری ماشین این است که روشی کمی برای ارزیابی مدارک فرضیه‌ها ارائه می‌کند. استدلال بیزی اساس الگوریتم‌های یادگیری‌ای که با استفاده از احتمالات کار می‌کنند است. همچنین استدلال بیز چارچوبی^۱ برای بررسی عملیات دیگر الگوریتم‌هایی که از احتمالات استفاده نمی‌کنند ایجاد می‌کند.

۶.۱ معرفی

متد‌های یادگیری بیزی به دو دلیل به مطالعه‌ی ما در مورد یادگیری ماشین مربوط می‌شود. اول اینکه الگوریتم‌های یادگیری بیزی احتمال صریح هر فرضیه، مثل دسته بندی کننده‌ی ساده‌ی بیز^۲، را محاسبه می‌کنند، این نوع روش‌ها از پر کاربردترین روش‌ها در حل بعضی از مسائل یادگیری هستند. برای مثال، (Michie 1994) تحقیقی در مورد تفاوت‌های دسته بندی کننده‌ی ساده‌ی بیز و دیگر الگوریتم‌های یادگیری، از جمله یادگیری درختی و شبکه‌های عصبی، ارائه می‌کند. این تحقیقات نشان می‌دهد که کارایی دسته بندی کننده‌ی ساده‌ی بیز در بعضی ویژگی‌ها ضعیف‌تر از دیگر الگوریتم‌ها و در بعضی ویژگی‌ها بهتر است. در این فصل دسته بندی کننده‌ی ساده‌ی بیز را به همراه چند مثال بررسی می‌کنیم. در کل، کاربرد این الگوریتم را روی مسئله‌ی دسته بندی متونی مثل مقالات خبری الکترونیک بررسی می‌کنیم. برای چنین کارهای یادگیری‌ای دسته بندی کننده‌ی ساده‌ی بیز یکی از بهترین الگوریتم شناخته شده است.

دلیل دوم اهمیت متد‌های بیز در مطالعه‌ی ما در یادگیری ماشین زمینه‌ی مساعدی است که این متد‌ها برای درک الگوریتم‌های یادگیری‌ای که مستقیماً با احتمالات کار نمی‌کنند ایجاد می‌کند. برای مثال، در این فصل، ما الگوریتم‌هایی چون Find-S و Candidate-Elimination،

¹ framework

² naive Bayes classifier

را که در فصل ۲ آمده بود، برای مشخص کردن شروطی که خروجی، محتمل‌ترین فرضیه‌ی سازگار با نمونه‌های آموزشی باشد را بررسی خواهیم کرد. همچنین با بررسی‌ای بیزی توجیهی برای یکی از انتخاب‌های کلیدی الگوریتم‌های یادگیری شبکه‌های عصبی (انتخاب تابع خطای مجموع مربعات خطا برای جستجوی فضای شبکه‌های عصبی ممکن) ارائه خواهیم کرد. همچنین در این بخش اشتقاق تابع خطای جایگزینی را محاسبه می‌کنیم، cross-entropy، این معیار زمانی که تابع هدف احتمالات را پیش بینی می‌کند از معیار مجموع خطاهای مربعی کارآمد تر است. از نظری بیزی بایاس استقرایی الگوریتم‌های درختی که به درخت‌های کوچک‌تر علاقه دارند و قانون کوتاه‌ترین طول توضیح را بررسی خواهیم کرد. آشنایی پایه‌ای با روش‌های بیزی برای درک بسیاری از الگوریتم‌های یادگیری ماشین اهمیت بسزایی دارد. ویژگی‌های متد‌های یادگیری بیزی شامل موارد زیر است:

- هر نمونه‌ی آموزشی می‌تواند احتمال تخمینی اینکه فرضیه درست است را کم یا زیاد کند. این حقیقت باعث می‌شود که روش‌های بیزی نسبت به الگوریتم‌هایی که کاملاً فرضیه را با نمونه‌های غیر سازگار رد می‌کنند انعطاف‌تر پذیر تر باشند.
- می‌توان از دانش قبلی به همراه داده‌های مشاهده شده برای تعیین احتمال نهایی درستی فرضیه‌ها استفاده کرد. در یادگیری بیزی، دانش قبلی با (۱) احتمال اولیه‌ی هر فرضیه و (۲) توزیع احتمال روی داده‌های تعیین شده برای هر فرضیه‌ی ممکن تعیین می‌شود.
- متد‌های بیزی می‌توانند برای فرضیه‌ها احتمالاتی را پیش بینی کنند (برای مثال، فرضیه‌ی "این بیمار ذات‌الریه با احتمال ۹۳٪ کاملاً بهبود خواهد یافت).
- نمونه‌های جدید را می‌توان با ترکیب پیش بینی‌های چندین فرضیه، (هر کدام با وزن احتمالشان) دسته بندی کرد.
- حتی هنگامی که اثبات می‌شود که متد‌های بیزی محاسباتی غیر قابل پیش بینی انجام می‌دهند، با این حال معیار استاندارد برای دیگر متد‌های عملی یادگیری مطرح می‌کنند.

یکی از مشکلات عملی کاربرد متد‌های بیزی نیاز آن‌ها به داشتن دانش اولیه از بسیاری از احتمالات است. هنگامی که این اطلاعات به طور دقیق در دسترس نیست، گاهی آن‌ها را با استفاده از دانش قبلی، داده‌های موجود قبلی، و فرض‌هایی درباره‌ی فرم توزیع تخمین می‌زنیم. دومین مشکل عملی کاربرد این متد‌ها هزینه‌ی محاسباتی قابل توجه آن‌ها برای تعیین فرضیه‌ی بهینه‌ی بیز در حالت کلی است (که رابطه خطی با تعداد فرضیه‌های ممکن دارد). در حالت‌های خاص این هزینه‌ی محاسباتی به طور قابل توجهی کاهش می‌یابد.

ادامه‌ی این فصل به شکل زیر ساختار بندی شده است. بخش ۶.۲ قضیه‌ی بیز را معرفی کرده و محتمل‌ترین^۱ و فرضیه‌ای با حداکثر احتمال ثانویه^۲ را تعریف خواهد کرد. چهار زیر بخش این بخش این چارچوب^۳ را برای بررسی چندین مشکل و الگوریتم یادگیری که در فصل‌های گذشته مطرح شد به کار می‌برند. برای مثال، نشان می‌دهیم که چندین الگوریتم مطرح شده با چه فرض‌هایی محتمل‌ترین فرضیه را خروجی می‌دهند. بخش‌های بعدی تعدادی از الگوریتم‌های یادگیری که منحصر با احتمالات کار می‌کنند را معرفی خواهند کرد. این الگوریتم‌ها شامل دسته بندی کننده‌ی بهینه‌ی بیز، الگوریتم گیبز و دسته بندی کننده‌ی ساده‌ی بیز می‌شود. بالاخره درباره‌ی شبکه‌ی باور بیز^۴ بحث خواهیم کرد و روشی جدید برای یادگیری بر اساس استدلال احتمالی و الگوریتم EM که الگوریتمی پرکاربرد در یادگیری در حضور متغیرهای غیر قابل مشاهده است را بررسی خواهیم کرد.

¹ maximum likelihood

² maximum a posteriori probability hypotheses

³ framework

⁴ Bayesian belief network

۶.۲ قضیه بیز

در یادگیری ماشین، گاهی سعی داریم که از میان فضای فرضیه های H بهترین فرضیه ی سازگار با نمونه های آموزشی D را پیدا کنیم. چندین راه برای تعریف "بهترین" در این جمله وجود دارد، یکی از این تعاریف "محتمل ترین" است، با در دست داشتن داده های D بدون نیاز به هیچ اطلاعات اولیه ی دیگر نمی توان محتمل ترین فرضیه را انتخاب کرد. قضیه ی بیز متدی مستقیم برای محاسبه ی احتمالات فرضیه های موجود در H ارائه می کند. به عبارت دیگر، قضیه ی بیز روشی برای محاسبه ی احتمال یک فرضیه بر اساس احتمال قبلی اش، احتمال مشاهده ی داده های سازگار با فرض درستی این فرضیه و احتمال خود داده های مشاهده شده ارائه می کند.

برای تعریف دقیق قضیه ی بیز، ابتدا بیا باید نشانه گذاری ها را معرفی کنیم. برای نشان دادن احتمال اولیه ی فرضیه ی h ، احتمال قبل از مشاهده ی داده های آموزشی، از $P(h)$ استفاده می کنیم. به $P(h)$ احتمال اولیه ی h نیز می گویند، این احتمال از اطلاعات قبلی ای که در مورد احتمال درستی فرضیه ی h داریم تأثیر می پذیرد. به طور مشابه از $P(D)$ برای نمایش احتمال اولیه ی مشاهده ی نمونه های آموزشی D استفاده می کنیم (مثلاً احتمال مشاهده ی D بدون داشتن هیچ اطلاعات قبلی در مورد اینکه با چه فرضیه هایی سازگار است). برای نشان دادن احتمال مشاهده ی D در جایی که فرضیه ی h درست است از $P(D|h)$ استفاده می کنیم. در حالت کلی، از $p(x|y)$ برای نشان دادن احتمال x با فرض وقوع y استفاده می کنیم. در مسائل یادگیری ماشین، علاقه ی ما به احتمال $P(h|D)$ است که در آن h یک فرضیه و D نمونه های آموزشی مشاهده شده هستند. به $P(h|D)$ احتمال ثانویه ی h نیز می گویند، زیرا که اطمینان ما به فرضیه ی h بعد از مشاهده ی نمونه های آموزشی D را نشان می دهد. توجه داشته باشید که احتمال ثانویه $P(h|D)$ بر خلاف احتمال اولیه $P(h)$ که از نمونه های آموزشی مستقل است، از نمونه های آموزشی D تأثیر می پذیرد.

قضیه بیز، اساس متد های یادگیری بیز است زیرا که راهی برای محاسبه ی احتمال ثانویه $P(h|D)$ از $P(h)$ ، $P(D)$ و $P(D|h)$.

قضیه بیز:

$$p(h|D) = \frac{p(D|h)P(h)}{p(D)} \quad (6.1)$$

همان طور که انتظار می رود، بر اساس قضیه ی بیز $P(h|D)$ با افزایش $P(h)$ و $P(D|h)$ افزایش می یابد. همچنین منطقی است که $P(h|D)$ ، با افزایش $P(D)$ کاهش یابد، زیرا که هر چه که احتمال مشاهده ی D به طور مستقل از h بالا تر رود دیگر D مدرکی برای درستی h نخواهد بود.

در بسیاری از مسائل یادگیری، یادگیر مجموعه ی فرضیه هایی مثل H را در نظر می گیرد و در بین آن ها به دنبال محتمل ترین فرضیه ی $h \in H$ با توجه به نمونه های آموزشی D می گردد (یا حداقل یکی از محتمل ترین فرضیه ها). هر کدام از این محتمل ترین، فرضیه با حداکثر

¹ prior probability

² posterior probability

احتمال ثانویه^۱ یا (MAP) نامیده می‌شود. فرضیه های MAP را می‌توان با استفاده از قضیه‌ی بیز برای محاسبه‌ی احتمال ثانویه‌ی هر فرضیه مشخص کرد. به صورت دقیق‌تر، زمانی می‌گوییم که فرضیه‌ی h_{MAP} یک فرضیه‌ی MAP است که

$$\begin{aligned} h_{MAP} &= \arg \max_{h \in H} P(h|D) \\ &= \arg \max_{h \in H} \frac{P(D|h)P(h)}{P(D)} \\ &= \arg \max_{h \in H} P(h|D) P(h) \end{aligned} \quad (6.2)$$

توجه داشته باشید که مرحله آخر عبارات بالا $P(D)$ چون ثابتی است و h بر آن تأثیری ندارد حذف می‌شود.

در بعضی موارد، فرض می‌کنیم که هر فرضیه در H احتمال اولیه‌ی مساوی‌ای دارد (برای هر h_i و h_j در H داریم که $P(h_i) = P(h_j)$). در این شرایط می‌توان رابطه‌ی ۶.۲ را بیشتر ساده کرد و کافی است که فقط عبارت $P(D|h)$ را برای پیدا کردن محتمل‌ترین فرضیه در نظر بگیریم. $P(D|h)$ گاهی محتمل بودن داده‌های D برای h نیز نامیده می‌شود و هر فرضیه‌ای که $P(D|h)$ را ماکزیمم کند (ML)^۲، h_{ML} نامیده می‌شود.

$$h_{ML} \equiv \arg \max_{h \in H} P(D|h) \quad (6.3)$$

برای مشخص شدن رابطه با مسائل یادگیری ماشین، ابتدا قضیه‌ی بیز را با توجه به نمونه‌های D و فضای فرضیه‌ی H معرفی کردیم. در واقع قضیه‌ی بیز کلی‌تر از آنچه در بالا گفته شد است. از قضیه‌ی بیز می‌توان برای هر زیر مجموعه‌ی H که ناسازگارند (اشتراک ندارند) استفاده کرد (مثل "آسمان آبی است" و "آسمان آبی نیست"). در این فصل، در اکثر موارد فرض خواهیم کرد که H فضای فرضیه‌ای که تابع هدف را شامل می‌شود است و D نمونه‌های آموزشی هستند. در مواقع دیگر فرض می‌کنیم که H مجموعه‌ی دیگر ناسازگاری با یکدیگر از فرضیه‌هاست و D نیز مجموعه‌ی دیگری از داده‌هاست.

۶.۲.۱ یک مثال

برای تصور قانون بیز، فرض کنید که مسئله‌ای برای تشخیص بیماری داریم، دو فرضیه‌ی ممکن برای بیماری وجود دارد: (۱) بیمار نوع خاصی از سرطان دارد و (۲) بیمار آن نوع سرطان را ندارد. داده‌های موجود یک تست آزمایشگاهی است که دو خروجی ممکن دارد: $\oplus$ (مثبت) و $\ominus$ (منفی). دانش قبلی داریم در کل جمعیت حاضر در آزمایش فقط ۰.۰۰۸. این بیماری را دارند. علاوه بر آن نتیجه‌ی آزمایش همیشه قطعی نیست و احتمال خطا وجود دارد. تست آزمایشگاهی در ۹۸٪ مواردی که بیمار بیماری را دارد نتیجه‌ی مثبت درست می‌دهد و در ۹۷٪ مواردی که بیمار بیماری را ندارد نتیجه‌ی منفی درست می‌دهد. در بقیه‌ی موارد آزمایش نتیجه‌ی اشتباه می‌دهد. آنچه در بالا گفته شد را خلاصه‌وار می‌توان به صورت زیر نشان داد:

$$P(cancer) = .008, \quad P(\neg cancer) = .992$$

¹ Maximum A Posteriori

² maximum likelihood

$$P(\oplus | cancer) = .98, \quad P(\ominus | \neg cancer) = .02$$

$$P(\oplus | \neg cancer) = .03, \quad P(\ominus | \neg cancer) = .97$$

فرض کنید که بیمار جدیدی پذیرش می شود و نتیجه ی آزمایش مثبت است. حال با چه احتمالی می توان گفت که بیمار سرطان دارد؟ فرضیه با حداکثر احتمال را می توان از رابطه ی ۶.۲ پیدا کرد:

$$P(\oplus | cancer)P(cancer) = (.98).008 = .0078$$

$$P(\oplus | \neg cancer)P(\neg cancer) = (.03).992 = .0298$$

پس، داریم $h_{MAP} = \neg cancer$. احتمال ثانویه ی فرضیه ها را می توان با رساندن مجموع دو احتمال به ۱ پیدا کرد (۲۱). $P(\oplus | cancer)P(cancer) = \frac{.0078}{.0078+.0298} = .21$. این مرحله برای این درست است که قضیه ی بیز احتمال های ثانویه مجموعه ی تمامی داده را بدون اشتراک می پوشانند (افراز می کنند) بیان می کند. با وجود اینکه $P(\oplus)$ مستقیماً توسط مسئله داده نشده است، اما می توان آن را محاسبه کرد زیرا که می دانیم مجموع دو احتمال $P(cancer | \oplus)$ و $P(\neg cancer | \oplus)$ یک است (هر بیمار یا سرطان دارد یا سرطان ندارد). توجه داشته باشید که احتمال ثانویه ی سرطان نسبت به احتمال اولیه ی آن به طور قابل توجهی زیاده است، اما با این حال محتمل ترین فرضیه این است که بیمار سرطان ندارد.

همان طور که در مثال بالا نشان داده شد، نتیجه ی تأثیر بیز به شدت به احتمال اولیه وابسته است، برای اینکه بتوان قضیه را به طور مستقیم به کار برد باید احتمالات اولیه معلوم باشند. توجه داشته باشید که در این مثال فرضیه ها کاملاً پذیرفته شده یا رد شده نیستند بلکه هر کدام با افزایش داده های مشاهده شده احتمالی پیدا می کنند. فرمول اصلی محاسبه ی احتمالات در جدول ۶.۱ خلاصه شده است.

۶.۳ قضیه ی بیز و یادگیری مفهوم

ارتباط بین قضیه ی بیز و مسائل یادگیری مفهوم چیست؟ از آنجایی که قضیه ی بیز راهی اصولی برای محاسبه ی احتمالات ثانویه ی هر یک از فرضیه ها بعد از مشاهده ی داده های آموزشی ارائه می کند، می توانیم از آن برای پایه ی یک الگوریتم یادگیری ساده استفاده کنیم، الگوریتمی که احتمال هر یک از فرضیه ها را محاسبه کرده و محتمل ترین فرضیه ها را خروجی می دهد. در این بخش چنین الگوریتم های بدون شعور^۱ یادگیری مفهوم بیز را بررسی و با الگوریتم های یادگیری مفهوم مقایسه می کنیم. همان طور که بعداً نیز خواهیم دید، یکی از نتایج جالب این مقایسه این است که تحت شرایط خاصی چندین الگوریتمی که در فصل های گذشته بررسی شدند همان فرضیه ای که یادگیری بدون شعور بیز خروجی می دهد را خروجی می دهند، با این تفاوت که آن ها احتمالات فرضیه ها را مشخص نمی کنند و فقط محتمل ترین را مشخص می کنند.

- قانون ضرب^۲: احتمال $P(A \wedge B)$ که احتمال عطف دو اتفاق A و B است را محاسبه کن

$$P(A \wedge B) = P(A | B)P(B) = P(B | A)P(A)$$

- قانون جمع^۱: احتمال فصل دو اتفاق A و B را محاسبه کن

¹ brute-force

² Product rule

$$P(A \vee B) = P(A) + P(B) - P(A \wedge B)$$

- قضیه بیز^۲: احتمال ثانویه ی $P(h|D)$ را محاسبه کن

$$P(h|D) = \frac{P(D|h)P(h)}{P(D)}$$

- قضیه ی مجموع احتمالات^۳: اگر اتفاق های $A_1, \dots, A_n$ دو به دو ناسازگار باشند و $\sum_{i=1}^n P(A_i) = 1$ خواهیم داشت

$$P(B) = \sum_{i=1}^n P(B|A_i)P(A_i)$$

جدول ۶.۱ خلاصه ی فرمول های پایه ای احتمال.

۶.۳.۱ یادگیری مفهوم بدون شعور بیز

مسئله ی یادگیری مفهومی را که در ابتدای فصل ۲ معرفی شد را در نظر بگیرید. در کل، فرض کنید که یادگیر فضای فرضیه ای محدود H را که شامل فرضیه هایی که بر فضای نمونه ای X تعریف شده اند است در نظر می گیرید و تابع هدف نیز مفهومی به فرم $c: X \rightarrow \{0,1\}$ است. مثل معمول، فرض می کنیم که به یادگیر دسته ای از نمونه های آموزشی مثل $\langle x_1, d_1 \rangle \dots \langle x_m, d_m \rangle$ داده می شود، در این نمونه های آموزشی x_i عضوی از X و d_i نیز مقدار هدف برای آن x_i است ($d_i = c(x_i)$). برای ساده سازی بحث در این بخش، فرض می کنیم که ترتیب نمونه های نمونه ها $\langle x_1 \dots x_m \rangle$ ثابت است پس می توان نمونه های آموزشی D را به فرم ساده به صورت $D = \langle d_1 \dots d_m \rangle$ نوشت. می توان نشان داد که این ساده نویسی تأثیری بر نتایج بدست آمده از این قسمت ندارد (تمرین ۶.۴).

می توان با استفاده از قضیه ی بیز الگوریتم یادگیری مفهوم مستقیمی طراحی کرد که فرضیه با حداکثر احتمال ثانویه را خروجی دهد:

الگوریتم یادگیری بدون شعور MAP^۴

۱. برای هر فرضیه h در H احتمال ثانویه را محاسبه کن،

$$p(h|D) = \frac{p(D|h)P(h)}{p(D)}$$

۲. فرضیه h_{MAP} را که بیشترین احتمال ثانویه را دارد خروجی بده

$$h_{MAP} = \arg \max_{h \in H} P(h|D)$$

¹ Sum rule

² Bayes theorem

³ Theorem of total probability

⁴ Brute-Force MAP Learning

این الگوریتم ممکن است محاسبات قابل توجهی نیاز داشته باشد، زیرا که قانون بیز را برای تمامی فرضیه های H برای محاسبه ی $P(h|D)$ به کار می برد. چنین حجم محاسباتی ای برای فضای فرضیه هایی با اندازه ی بالا غیر عملی است، با این وجود الگوریتم هنوز مورد توجه است زیرا که معیاری ارائه می کند در حالی که دیگر الگوریتم های یادگیری مفهوم هیچ معیاری ارائه نمی کنند.

برای آماده سازی یک مسئله برای حل با الگوریتم یادگیری بدون شعور MAP لازم است که مقادیر $P(h)$ و $P(D|h)$ را مشخص کنیم (همان طور که بعداً هم خواهیم دید با مشخص کردن مقادیر ذکر شده مقدار $P(D)$ نیز مشخص می شود). اطلاعات اولیه ی ما در مورد مسئله با تعیین دو توزیع $P(h)$ و $P(D|h)$ به طور دلخواه مشخص می شود. بیا بیا ابتدا با فرض های زیر شروع کنیم :

۱. نمونه های آموزشی D خطا ندارند ($d_i = c(x_i)$)

۲. مفهوم هدف C در فضای فرضیه ای H موجود است.

۳. هیچ مدرکی بر برتری یک فرضیه بر فرضیه ی دیگر وجود ندارد.

با فرض های بالا، چه مقداری باید برای $P(h)$ تعیین شود؟ بدون هیچ اطلاعات قبلی، برتری فرضیه ها بر یکدیگر بی دلیل خواهد بود، می توانیم احتمال تمامی آن ها را مساوی قرار دهیم. علاوه بر آن، چون فرض کرده ایم تابع هدف C در H موجود است باید طوری احتمال را پخش کنیم که مجموع احتمال کل H یک باشد. پس خواهیم داشت:

$$P(h) = \frac{1}{|H|} \text{ for all } h \text{ in } H$$

اما $P(D|h)$ چه احتمالی باید داشته باشد؟ $P(D|h)$ احتمال مشاهده ی مقادیر هدف $D = \langle d_1 \dots d_n \rangle$ است که برای دسته ی ثابت نمونه ها زمانی که h درست است می باشد. (مثلاً زمانی که h همان مفهوم هدف C است). از آنجایی که فرض کردیم داده های آموزشی خطا ندارند، احتمال دیدن d_i اگر $d_i = h(x_i)$ باشد ۱ و اگر $d_i \neq h(x_i)$ باشد ۰ است. بنابراین،

$$P(D|h) = \begin{cases} 1 & \text{if } d_i = h(x_i) \text{ for all } d_i \text{ in } D \\ 0 & \text{otherwise} \end{cases} \quad (6.4)$$

به عبارت دیگر احتمال مشاهده ی D با داشتن h ، ۱ است اگر h سازگار باشد و در غیر این صورت ۰ است.

با این نوع انتخاب $P(h)$ و $P(D|h)$ حال مسئله را کاملاً برای الگوریتم یادگیری بدون شعور MAP آماده کرده ایم. مرحله ی اول این الگوریتم که در آن با استفاده از قضیه ی بیز احتمال ثانویه ی $P(h|D)$ برای تمامی h ها با توجه به نمونه های آموزشی D محاسبه می شود را در نظر بگیرید. با توجه به قضیه ی بیز داریم،

$$p(h|D) = \frac{p(D|h)P(h)}{p(D)}$$

ابتدا فرض کنید که h با نمونه های آموزشی ناسازگار است. از رابطه ی ۶.۴ داریم که $P(D|h)$ صفر است زیرا که h با D ناسازگار است پس داریم که:

$$P(h|D) = \frac{0 \cdot P(h)}{P(D)} = 0 \text{ if } h \text{ is inconsistent with } D$$

پس احتمال ثانویه‌ی فرضیه‌ی ناسازگار با D صفر خواهد بود.

حال فرض کنید که فرضیه‌ی h با D سازگار است. از رابطه‌ی ۶.۴ داریم که $P(D|h)$ یک فرض شده است زیرا که h با D سازگار است. داریم،

$$\begin{aligned} P(h|D) &= \frac{1 \cdot \frac{1}{|H|}}{P(D)} \\ &= \frac{1 \cdot \frac{1}{|H|}}{\frac{|VS_{H,D}|}{|H|}} \\ &= \frac{1}{|VS_{H,D}|} \text{ if } h \text{ is consistent with } D \end{aligned}$$

در این رابطه $VS_{H,D}$ زیر مجموعه‌ای از H است که با D سازگار است (مثلاً $VS_{H,D}$ می‌تواند همان فضای ویژه‌ای فصل ۲ باشد که با توجه به D بدست آمده). تشخیص اینکه $P(D) = \frac{|VS_{H,D}|}{|H|}$ کار ساده‌ای است زیرا که مجموع $P(h|D)$ برای تمامی فرضیه‌ها باید ۱ باشد و از طرفی تعداد کل فرضیه‌های سازگار با D در H طبق تعریف $|VS_{H,D}|$ است. می‌توان مقدار $P(D)$ را از قضیه‌ی مجموع احتمال (در جدول ۶.۱) و این حقیقت که فرضیه‌ها دو به دو ناسازگارند $((\forall i \neq j)(P(h_i \wedge h_j) = 0))$ بدست آورد.


$$\begin{aligned} P(D) &= \sum_{h_i \in H} P(D|h_i)P(h_i) \\ &= \sum_{h_i \in VS_{H,D}} 1 \cdot \frac{1}{|H|} + \sum_{h_i \notin VS_{H,D}} 0 \cdot \frac{1}{|H|} \\ &= \sum_{h_i \in VS_{H,D}} 1 \cdot \frac{1}{|H|} \\ &= \frac{|VS_{H,D}|}{|H|} \end{aligned}$$

به طور خلاصه اینکه با فرض‌هایی که در مورد $P(h)$ و $P(D|h)$ کردیم قضیه‌ی زیر ایجاب می‌کند که $P(h|D)$ به صورت زیر باشد:

$$P(h|D) = \begin{cases} \frac{1}{|VS_{H,D}|} & \text{if } h \text{ is consistent with } D \\ 0 & \text{otherwise} \end{cases} \quad (6.5)$$

در این رابطه $|VS_{H,D}|$ تعداد فرضیه های H که با D سازگارند است. شکل ۶.۱ سیر تکامل احتمالات را با نمودار نشان می دهد. ابتدا (شکل 6.1 (a)) تمامی فرضیه ها احتمال یکسانی دارند. با افزایش داده های آموزشی (شکل های 6.1 (b) و 6.1 (c)) احتمال ثانویه ی فرضیه های ناسازگار صفر می شود اما مجموع کل احتمالات ۱ باقی می ماند، یعنی احتمال فرضیه هایی که صفر می شود به طور مساوی در بین فرضیه های دیگر تقسیم می شود.

بررسی بالا نشان داد با انتخاب $P(h)$ و $P(D|h)$ تمامی فرضیه های سازگار احتمال ثانویه ی مساوی $(1/|VS_{H,D}|)$ خواهند داشت و احتمال فرضیه های ناسازگار صفر خواهد شد. پس با توجه به این بررسی هر فرضیه ی سازگار یک MAP (فرضیه با حداکثر احتمال) است.



شکل ۶.۱ تکامل احتمال ثانویه ی $P(h|D)$ با افزایش داده های آموزشی. (a) اولویت یکسان به تمامی فرضیه ها داده می شود. با افزایش داده ها به $D1$ (b) و سپس به $D1/D2$ (c)، احتمال ثانویه ی فرضیه های ناسازگار به صفر می رسد در حالی که احتمال ثانویه برای فرضیه های فضای ویژه افزایش می یابد.

۶.۳.۲ فرضیه های MAP و یادگیرهای سازگار

بررسی های بالا نشان می دهد که با مفروضات مذکور تمامی فرضیه های سازگار با D فرضیه ای MAP هستند. این عبارت را می توان مستقیماً به عبارتی جالب در مورد دسته ای از یادگیرها که یادگیرهای سازگار^۱ می نامیم تفسیر کرد. زمانی می گوییم که یک الگوریتم یادگیری یادگیر سازگار است که فرضیه ی خروجی هیچ خطایی بر روی داده های آموزشی نداشته باشد. بر اساس بررسی بالا، می توان گفت تمامی یادگیرهای سازگار فرضیه ی خروجیشان یک فرضیه ی MAP است، به شرطی که فرض کنیم که توزیع اولیه احتمال روی H یکنواخت باشد $((\forall i, j) P(h_i) = P(h_j))$ و همچنین فرض کنیم که داده های آموزشی قطعی و بدون خطا هستند $P(D|H)=1$ اگر D با h سازگار باشد و در غیر این صورت صفر است).

برای مثال، الگوریتم یادگیری مفهوم Find-S را که در فصل ۲ بررسی شد را در نظر بگیرید. Find-S فضای فرضیه ای H را از فرضیه های جزئی تر به کلی تر جستجو می کند تا جزئی ترین فرضیه ی سازگار را پیدا کند (جزئی ترین عضو فضای ویژه). چون Find-S فرضیه ای سازگار را خروجی می دهد پس طبق احتمالات مفروض بالا برای $P(h)$ و $P(D|h)$ فرضیه ای MAP را خروجی خواهد داد. البته Find-S هیچ

¹ consistent learner

احتمالی را محاسبه و ارائه نمی کند و فقط خاص ترین فرضیه ی فضای ویژه را پیدا می کند. با این وجود، با مشخص کردن توزیع های $P(h)$ و $P(D|h)$ به صورتی که فرضیه ی خروجی MAP باشد، روشی مفید برای مشخص کردن رفتار Find-S داریم.

آیا توزیع احتمال های دیگری برای $P(h)$ و $P(D|h)$ وجود دارد که خروجی FIND-S فرضیه ی MAP باشد؟ بله، چون FIND-S خاص ترین فرضیه ی فضای ویژه را پیدا می کند فرضیه ی خروجی اش با اختصاص توزیع احتمال هایی که به سمت فرضیه های خاص تر تمایل دارند MAP خواهد بود. به عبارت دقیق تر، فرض کنید که $\mathcal{H}$ تمامی توزیع احتمال $P(h)$ روی H است که در آن ها داریم $P(h_1) \geq P(h_2)$ اگر h_1 خاص تر از h_2 باشد. می توان نشان داد با چنین توزیع احتمال هایی و توزیع احتمال مذکور برای $P(D|h)$ فرضیه ی خروجی FIND-S یک فرضیه ی MAP خواهد بود.

خلاصه بحث بالا بدین شکل است، چارچوب بیزی به ما اجازه می دهد تا ویژگی های رفتاری الگوریتم های یادگیری (حتی الگوریتم هایی که مقدار احتمال فرضیه را مشخص نمی کنند، مثل FIND-S) را مشخص کنیم. با مشخص کردن توزیع احتمال های $P(h)$ و $P(D|h)$ به صورتی که فرضیه ی خروجی الگوریتم بهینه، MAP، شود، پیش فرض هایی که الگوریتم برای نتیجه گیری انجام می دهد را می توان پیدا کرد.

استفاده از دیدگاه بیزی برای بررسی ویژگی های الگوریتم های یادگیری بدین صورت عملاً مشابه بررسی بایاس استقرایی یادگیرهاست. در فصل ۲ ما بایاس استقرایی یک الگوریتم را دسته پیش فرض هایی مثل B تعریف کردیم که نحوه ی استقرای یادگیر را توجیه می کند. برای مثال، گفته شد که بایاس استقرایی الگوریتم Candidate-Elimination وجود مفهوم هدف C در مجموعه ی فرضیه ای H است. علاوه بر آن نشان دادیم که خروجی این الگوریتم یادگیری را می توان از ورودی هایش و این پیش فرض استقرایی ضمنی نتیجه گرفت. تفسیری بیزی بالا می تواند جایگزینی برای بررسی ویژگی های این پیش فرض های الگوریتم های یادگیری باشد. با این تفاوت که در اینجا به جای مدل کردن الگوریتم با یک سیستم معادل استقرایی، الگوریتم را با سیستم معادل استدلال احتمالی^۱ که بر اساس قضیه ی بیز کار می کند، مدل سازی می کنیم. و در اینجا پیش فرض هایی که یادگیر فرض می کند به فرم "احتمال اولیه های فرضیه ها $P(h)$ و قدرت داده ها در قبول یا رد فرضیه ها $P(D|h)$ " است. تعریف $P(h)$ و $P(D|h)$ که در این قسمت معرفی شد مربوط به دو الگوریتم Candidate-Elimination و FIND-S بود. سیستم استدلال احتمالی ای که بر اساس قضیه ی بیز کار می کند، با این توزیع ها در ورودی و خروجی رفتاری مشابه این الگوریتم ها از خود نشان خواهد داد.

بحثی که در این بخش انجام شد حالت خاصی از استدلال بیزی بود زیرا که فرض کردیم داده های آموزشی بدون خطا باشند و فرضیه ها نیز قطعی اند، یعنی $P(D|h)$ حتماً یکی از دو مقدار ۱ یا ۰ را دارد. همان طور که در قسمت بعدی نیز خواهیم دید، می توان یادگیری از نمونه های آموزشی خطا دار را شبیه سازی کرد، فقط کافی است که مقدار $P(D|h)$ مقادیری غیر ۰ و ۱ را نیز داشته باشد، با این تغییر توزیع احتمال $P(D|h)$ خطا را کنترل خواهد کرد.

¹ probabilistic reasoning system

۶.۴ محتمل ترین فرضیه‌ها^۱ و فرضیه‌هایی که کمترین خطای مربعی^۲ را دارند

همان طور که در بالا نیز نشان داده شد تحت شرایطی یک الگوریتم یادگیری فرضیه های MAP را خروجی می‌دهد حتی اگر این الگوریتم از روش بیز یا حتی از محاسبه‌ی احتمال‌ها استفاده نکند.

در این بخش، به مسئله‌ی یادگیری توابع هدف پیوسته مقدار می‌پردازیم، مسئله‌ی که راه‌های زیادی برای آن مثل شبکه‌های عصبی، تقریب خطی، و تقریب چند جمله‌ای ارائه شده است. یک بررسی مستقیم بیزی نشان می‌دهد که در شرایط خاصی هر الگوریتم یادگیری که خطای مربعی بین تخمین و خروجی داده‌های آموزشی را مینیمم کند یک محتمل ترین فرضیه^۳ را خروجی می‌دهد. اهمیت این نتیجه در استفاده از این استدلال بیزی (تحت شرایط خاص) برای توجیه بسیاری از شبکه‌های عصبی و دیگر متدهایی که مجموع خطای مربعی را مینیمم می‌کنند است.


شرایط مسئله‌ی یادگیری تابع هدف پیوسته را در نظر بگیرید، یادگیر L که از فضای نمونه‌ی X و فضای فرضیه‌ی H که مجموعه‌ی $\mathcal{H}$ از توابع حقیقی مقدار روی نمونه‌های X استفاده می‌کند (هر h در H تابعی است به فرم $h: X \rightarrow \mathcal{R}$ ، که در آن $\mathcal{R}$ مجموعه‌ی اعداد حقیقی است). مسئله‌ی L با آن مواجه است یادگیری تابع هدف مجهول $f: X \rightarrow \mathcal{R}$ از مجموعه‌ی فرضیه‌های H است. مجموعه‌ی m نمونه‌ی آموزشی در دسترس است، در این مجموعه مقدار تابع هدف هر یک از نمونه‌ها با یک مقدار تصادفی خطا که توزیع نرمال دارد معلوم است. به عبارت دقیق‌تر، هر نمونه‌ی آموزشی زوج مرتبی به فرم $\langle x_i, d_i \rangle$ است که در آن $d_i = f(x_i) + e_i$. در اینجا $f(x_i)$ خود تابع هدف و مقدار e_i متغیر تصادفی خطاست. فرض می‌شود که مقدار e_i مستقل و دارای توزیع نرمال با میانگین صفر است. هدف یادگیر نیز پیدا کردن محتمل ترین فرضیه، یا به صورت معادل، یک فرضیه‌ی MAP است با این فرض که تمامی فرضیه‌ها احتمال اولیه‌ی یکسانی دارند.

با وجود اینکه بررسی‌هایمان را برای یادگیری توابع دلخواه حقیقی مقدار انجام می‌دهیم، مسئله‌ی یادگیری تابع خطی نمونه‌ای از چنین مسائلی است. شکل ۶.۲ شکل تابع هدف خطی f را به همراه چندین نمونه‌ی آموزشی نشان داده است. خط چین فرضیه‌ی h_{ML} است که کمترین خطای مربعی را دارد، پس محتمل ترین فرضیه است. توجه داشته باشید که محتمل ترین فرضیه حتماً فرضیه‌ی درست نیست، زیرا که مجموعه‌های آموزشی محدود و خطا دار هستند.

¹ maximum likelihood

² least squared error

³ maximum likelihood



شکل ۶.۲ یادگیری تابع حقیقی مقدار.

تابع هدف f با خط نشان داده شده است. نمونه های آموزشی $\langle x_i, d_i \rangle$ با فرض اینکه خطایی با توزیع نرمال با میانگین صفر دارند در نظر گرفته شده اند. خط چین تابعی خطی را نشان می دهد که میزان خطای مربعی را مینیمم می کند. بنابراین این فرضیه محتمل ترین فرضیه، h_{ML} بر اساس ۵ نمونه ی آموزشی موجود است.

قبل از اینکه به اثبات محتمل ترین بودن فرضیه هایی که خطای مربعی را مینیمم می کنند در شرایط مذکور بپردازیم؛ ابتدا بیایید دو مفهوم را از تئوری احتمال مرور کنیم: چگالی احتمال و توزیع نرمال. ابتدا برای بحث روی متغیر های تصادفی پیوسته مثل e ، ابتدا باید چگالی احتمال را معرفی کنیم. دلیل اولیه این پیش زمینه ها این است که می خواهیم مجموع احتمالات روی تمامی مقادیر ممکن متغیر تصادفی یک باشد. در این حالت که متغیر های تصادفی پیوسته هستند، تعیین احتمال را نمی توان با نسبت دادن یک احتمال به هر یک از مقادیر ممکن متغیر تصادفی انجام داد. به جای آن، از چگالی احتمال^۱ برای مقادیر تصادفی حقیقی مثل e استفاده می کنیم و انتگرال روی کل چگالی احتمال را مساوی یک قرار می دهیم. در کل از حرف کوچک p برای نشان دادن تابع چگالی احتمال استفاده می کنیم و احتمال را با حرف بزرگ P نشان می دهیم (گاهی اوقات این مقدار جرم احتمال^۲ نیز نامیده می شود). چگالی احتمال $p(x_0)$ ، $\frac{1}{\varepsilon}$ برابر مقدار احتمال اینکه متغیر تصادفی در بازه ای $[x_0, x_0 + \varepsilon)$ زمانی که $\varepsilon \rightarrow 0$ قرار بگیرد است.

چگالی احتمال:

$$p(x_0) \equiv \lim_{\varepsilon \rightarrow 0} \frac{1}{\varepsilon} P(x_0 \leq x < x_0 + \varepsilon)$$

¹ probability density

² probability mass

دوم اینکه e را در مسئله طوری تعریف کردیم که از توزیع احتمال نرمال پیروی می کند. توزیع احتمال نرمال، توزیع احتمالی هموار و زنگی شکل است که می توان آن را با میانگین μ و انحراف معیار σ کاملاً مشخص کرد. برای تعریف دقیق تر به جدول ۵.۴ مراجعه کنید.

حال با داشتن این پیش زمینه ها می توانیم به موضوع اصلی برگردیم: در شرایط مذکور، نشان می دهیم که فرضیه هایی که خطای مربعی را مینیمم می کنند در واقع همان محتمل ترین فرضیه ها هستند. ابتدا محتمل ترین تابع را با استفاده از رابطه ی 6.3 مشخص می کنیم، با این تفاوت که توزیع احتمال در این رابطه را با p نشان می دهیم.

$$h_{ML} = \arg \max_{h \in H} p(D|h)$$

مثل قبل، فرض می کنیم که مجموعه ای از نمونه های آموزشی مثل $\langle x_1 \dots x_n \rangle$ با مقدار تابع هدفشان D ، $D = \langle d_1 \dots d_2 \rangle$ داریم. در اینجا $d_i = f(x_i) + e_i$. با فرض اینکه نمونه های آموزشی کاملاً مستقل از فرضیه ی h هستند $P(D|h)$ را می توان بر حسب $p(d_i|h)$ ها نوشت

$$h_{ML} = \arg \max_{h \in H} \prod_{i=1}^m p(d_i|h)$$

با دانستن اینکه e_i ها از توزیع نرمال با میانگین صفر و واریانس مجهول σ^2 پیروی می کنند، هر d_i نیز باید از توزیع نرمالی با واریانس σ^2 و میانگین $f(x_i)$ ، به جای صفر، پیروی کند. بنابراین $p(d_i|h)$ را می توان به صورت توزیع نرمالی با واریانس σ^2 و میانگین $\mu = f(x_i)$ نوشت. بیایید فرمول این توزیع نرمال را که $p(d_i|h)$ را توصیف می کند بنویسیم، ابتدا فرمولی که در جدول ۵.۴ آمده را می نویسیم و مقادیر μ و σ^2 را جایگزین می کنیم. چون رابطه ای برای d_i با فرض اینکه فرضیه ی h توصیف درست از تابع هدف f است می نویسیم، خواهیم داشت که $\mu = f(x_i) = h(x_i)$

$$\begin{aligned} h_{ML} &= \arg \max_{h \in H} \prod_{i=1}^m \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2\sigma^2}(d_i-\mu)^2} \\ &= \arg \max_{h \in H} \prod_{i=1}^m \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2\sigma^2}(d_i-h(x_i))^2} \end{aligned}$$

حال از تبدیلی استفاده می کنیم که در اکثر محاسبات محتمل ترین ها متداول است: به جای ماکزیمم کردن مقدار کل عبارت، لگاریتم آن را که بسیار ساده تر است ماکزیمم می کنیم. زیرا که تابع $\ln p$ تابعی یکنواخت و صعودی از p است. بنابراین ماکزیمم کردن $\ln p$ باعث ماکزیمم شدن خود p می شود.

$$h_{ML} = \arg \max_{h \in H} \sum_{i=1}^m \ln \frac{1}{\sqrt{2\pi\sigma^2}} - \frac{1}{2\sigma^2} (d_i - h(x_i))^2$$

جمله‌ی اول مستقل از h است و بنابراین می‌توان آن را حذف کرد،

$$h_{ML} = \arg \max_{h \in H} \sum_{i=1}^m -\frac{1}{2\sigma^2} (d_i - h(x_i))^2$$

ماکزیمم کردن این کمیت منفی مشابه مینیمم کردن مقدار مثبت آن است،

$$h_{ML} = \arg \min_{h \in H} \sum_{i=1}^m \frac{1}{2\sigma^2} (d_i - h(x_i))^2$$

و دوباره می‌توان ثابتی که مستقل از h است را حذف کرد و داریم:

$$h_{ML} = \arg \min_{h \in H} \sum_{i=1}^m (d_i - h(x_i))^2 \quad (6.6)$$

رابطه‌ی ۶.۶ نشان می‌دهد که محتمل‌ترین فرضیه h_{ML} فرضیه‌ای است که مجموع خطاهای مربعی بین مقادیر هدف نمونه‌های آموزشی d_i و پیش‌بینی فرضیه $h(x_i)$ را مینیمم کند. این نتیجه‌گیری‌ها با این فرض بود که نمونه‌های آموزشی، d_i ها، مقادیر تابع هدف به اضافه‌ی مقدار خطای تصادفی با توزیع نرمال و میانگین صفر هستند. همان‌طور که استخراج عبارت بالا نیز نشان می‌دهد، مقدار جمله‌ی مربعی خطای $(d_i - h(x_i))^2$ مستقیماً از توزیع نرمال ناشی شده است. با استفاده از دیگر توزیع‌های خطا می‌توان تعریف‌های دیگری برای خطا بدست آورد.

توجه داشته باشید که ساختار اشتقاق بالا شامل انتخاب فرضیه‌ای که لگاریتم محتمل بودن $(\ln p(D|h))$ را حداکثر می‌کند به عنوان محتمل‌ترین فرضیه نیز می‌شود. همان‌طور که پیش‌تر نیز گفته شد، این مشابه این است که محتمل بودن $(\ln p(D|h))$ را حداکثر کنیم. این روش کار با لگاریتم محتمل بودن^۱ در بسیار از بررسی‌های بیزی مورد استفاده قرار می‌گیرد، زیرا که کار با لگاریتم محتمل بودن بسیار ساده‌تر از کار با خود محتمل بودن است. البته، همان‌طور که قبلاً هم گفته شد، محتمل‌ترین فرضیه همیشه فرضیه‌ی MAP نیست مگر اینکه احتمال اولیه‌ی تمامی فرضیه‌ها مساوی فرض شود.

چرا استفاده از توزیع نرمال برای مدل سازی نویز یا همان خطای نمونه‌ها استفاده می‌کنیم؟ یکی از دلایلی که لازم است حتماً ذکر شود، این است که بررسی را از نظر ریاضی بسیار ساده‌تر می‌کند. دلیل دوم این است که این توزیع توزیعی هموار است و توزیع‌های زنگی شکل تخمین خوبی برای بسیاری از انواع خطاها در سیستم‌های فیزیکی هستند. در واقع، طبق قضیه‌ی حد مرکزی که در فصل ۵ توضیح داده شد، مجموع تعداد زیادی از متغیرهای مستقل و هم توزیع بدون توجه به نوع توزیع از توزیع نرمال پیروی می‌کند. این ثابت می‌کند که خطا که خود از مجموع تعداد زیادی متغیر مستقل و با ضریب توزیع یکسان تولید می‌شود از توزیع نرمال پیروی خواهد می‌کند. البته در واقعیت، مؤلفه‌های مختلفی که در نویز تأثیر گذارند همگی از یک توزیع پیروی نمی‌کنند، که در این شرایط این قضیه توجیهی برای استفاده از این توزیع نیست.

¹ likelihood

مینیم کردن مجموع خطای مربعی روشی متداول در بسیاری از شبکه های عصبی، منحنی های تخمین و ... در تخمین توابع حقیقی مقدار است. فصل ۴ روش شیب نزول را که مینیم کردن خطای مربعی در شبکه های عصبی را با آن انجام می دهیم مفصلاً توضیح داده است.

بد نیست که قبل از اتمام بحث رابطه ی بین محتمل ترین فرضیه و فرضیه ای که خطای مربعی را مینیم می کند، بعضی محدودیت ها این شرایط مسئله را ذکر کنیم. بررسی بالا فقط خطا در تابع هدف نمونه های آموزشی در نظر گرفته شده است و از خطای خود ویژگی هایی که نمونه را توصیف می کنند صرف نظر شده بود. برای مثال، اگر مسئله یادگیری پیش بینی وزن افراد بر اساس سن و قدشان باشد، در شرایط ذکر شده فقط می توان خطا را برای وزن در نظر گرفت و مقادیر سن و قد دقیق فرض می شوند. بررسی زمانی پیچیده تر می شود که فرض های ساده کننده حذف شوند.

۶.۵ محتمل ترین فرضیه برای مسائل پیش بینی

در تعریف مسئله ی قسمت قبلی محتمل ترین فرضیه را فرضیه ای مشخص کردیم که مجموع خطای مربعی را بر روی نمونه های آموزشی مینیم می کند. در این بخش معیاری مشابه برای تعریف مسئله ی دیگری که در شبکه های عصبی متداول است بیان می کنیم: یادگیری پیش بینی احتمالات.

حالتی را در نظر بگیرید که در آن می خواهیم تابعی غیر قطعی (احتمالی) $f: X \rightarrow \{0,1\}$ را یاد بگیریم که دو خروجی گسسته دارد. برای مثال، فضای نمونه ای X ممکن است توصیف بیماران با علائم بیماریشان باشد، و تابع هدف $f(x)$ زمانی که بیمار زنده بماند ۱ و در غیر این صورت ۰ باشد. یا به طور مشابه X می تواند توصیف مراجعین دریافت وام با وضعیت حسابشان در گذشته باشد و $f(x)$ زمانی که وام بعدی کامل پرداخت می شود ۱ و در غیر این صورت ۰ باشد. برای مثال، در مجموعه ای از بیماران که علائم مشترکی دارند ۹۲٪ درصد زنده می مانند و ۸٪ جان سالم به در نمی برند. این عدم قطعیت ممکن است ناشی از ناتوانی ما را در مشاهده ی تمامی علائم مهم بیمار باشد یا ممکن است ناشی از یک فرایند تصادفی در پیشرفت بیماری باشد. جدا از اینکه منشأ مشکل چیست، ما تابع هدف $f(x)$ را داریم که به صورت احتمالی روی این ورودی عمل می کند.

با این تعریف مسئله ممکن است از یک شبکه ی عصبی (یا تخمین زنده ی توابع حقیقی مقدار دیگر) که خروجی اش احتمال $f(x)=1$ باشد استفاده کنیم. به عبارت دیگر، ما دنبال یادگیری تابع هدف $f': X \rightarrow [0,1]$ هستیم که در آن $f'(x)=P(f(x)=1)$. در مثال بالا، اگر آن علائم غیر قابل تمیز را داشته باشیم به احتمال ۹۲٪ بیمار زنده می ماند، پس $f'(x)=0.92$ که یعنی احتمال اینکه $f(x)$ برابر با ۱ باشد ۹۲٪ است، و احتمال اینکه $f(x)$ برابر با ۰ باشد، ۸٪ است.

چگونه می توان f' را با روشی مثل شبکه های عصبی یاد گرفت؟ یکی از راه های غیر هوشمندانه جمع کردن تعداد تکرار ۱ ها و ۰ های تابع برای هر نمونه ی ممکن x و آموزش شبکه ی عصبی با نسبت این تعداد تکرارهاست. همان طور که در ادامه نیز خواهیم دید، به جای این کار می توان از خود نمونه های آموزشی f برای آموزش شبکه ی عصبی استفاده کرد و محتمل ترین فرضیه برای f' را بدست آورد.

چه معیاری را بهینه می کنیم تا محتمل ترین فرضیه در این تعریف مسئله را بیابیم؟ برای جواب این سؤال ابتدا باید رابطه ای برای $P(D|h)$ پیدا کنیم. بیایید فرض کنیم که نمونه های آموزش D به فرم $D = \{ \langle x_1, d_1 \rangle \dots \langle x_m, d_m \rangle \}$ هستند که در آن d_i ها مقدار مشاهده شده ی $f(x_i)$ است.

$$P(D|h) = \prod_{i=1}^m P(x_i, d_i|h) \quad (6.7)$$
$$P(D|h) = \prod_{i=1}^m P(x_i, d_i|h) = \prod_{i=1}^m P(d_i|h, x_i)P(x_i) \quad (6.8)$$
$$P(d_i|h, x_i) = \begin{cases} h(x_i) & \text{if } d_i = 1 \\ (1 - h(x_i)) & \text{if } d_i = 0 \end{cases} \quad (6.9)$$
$$P(d_i|h, x_i) = h(x_i)^{d_i}(1 - h(x_i))^{1-d_i} \quad (6.10)$$

می‌توان از رابطه‌ی ۶.۱۰ برای جایگزینی $P(d_i|h, x_i)$ در رابطه‌ی ۶.۸ استفاده کرد،

$$P(D|h) = \prod_{i=1}^m h(x_i)^{d_i} (1 - h(x_i))^{1-d_i} P(x_i) \quad (6.11)$$

حال می‌توانیم رابطه‌ی محتمل‌ترین فرضیه را بنویسیم،

$$h_{ML} = \arg \max_{h \in H} \prod_{i=1}^m h(x_i)^{d_i} (1 - h(x_i))^{1-d_i} P(x_i)$$

جمله‌ی آخری مستقل از h است و می‌توان آن را حذف کرد،

$$h_{ML} = \arg \max_{h \in H} \prod_{i=1}^m h(x_i)^{d_i} (1 - h(x_i))^{1-d_i} \quad (6.12)$$

عبارت سمت راست رابطه‌ی ۶.۱۲ را می‌توان در تعمیم توزیع دو جمله‌ای در جدول ۵.۳ دید. عبارت رابطه‌ی 6.12 احتمال ظهور برآمد $d_1 \dots d_m < h(x_i) >$ را با فرض اینکه هر سکه‌ی x_i احتمال شیر آمدن $h(x_i)$ را داشته باشد را نشان می‌دهد. توجه داشته باشید که توزیع دو جمله‌ای که در جدول ۵.۳ آمد مشابه این رابطه است، اما فرض دیگری نیز دارد، احتمال شیر آمدن برای تمامی سکه‌ها را مساوی فرض می‌کند $(h(x_i) = h(x_j), \forall i, j)$. اما در هر دو حالت فرض می‌کنیم که برآمد پرتاب سکه‌ها ناسازگارند، فرضی که در تعریف مسئله فعلی ما نیز صدق می‌کند.

مشابه گذشته، کار با لگاریتم محتمل بودن راحت‌تر از خود محتمل بودن است پس داریم:

$$h_{ML} = \arg \max_{h \in H} \sum_{i=1}^m d_i \ln h(x_i) + (1 - d_i) \ln(1 - h(x_i)) \quad (6.13)$$

رابطه‌ی ۶.۱۳ کمیتی را نشان می‌دهد که برای پیدا کردن محتمل‌ترین فرضیه در تعریف مسئله‌ی فعلی ماکزیمم می‌کنیم. این نتیجه مشابه نتیجه‌ی قبلی ما در مینیمم کردن مجموع خطای مربعی محتمل‌ترین فرضیه در تعریف مسئله‌ی قبلی است. به شباهت بین رابطه‌ی 6.13 و فرم کلی تابع آنتروپی $-\sum_i p_i \log p_i$ که در فصل ۳ آمد توجه کنید. بخاطر این شباهت، قرینه‌ی عبارت بالا گاهی آنتروپی دورگه^۱ نامیده می‌شود.

۶.۵.۱ شیب نزول برای پیدا کردن محتمل‌ترین فرضیه در یک شبکه‌ی عصبی

در بالا نشان دادیم که با ماکزیمم کردن کمیت رابطه‌ی ۶.۱۳ محتمل‌ترین فرضیه بدست خواهد آمد. بیایید این کمیت را با اختصار $G(h, D)$ نشان دهیم. در این بخش قانونی برای آموزش وزن‌ها^۲ برای شبکه‌های عصبی بدست خواهیم آورد که $G(h, D)$ را توسط روش شیب نزول ماکزیمم می‌کند.

همان طور که در فصل ۴ نیز بحث شد، گرادیان $G(h, D)$ توسط بردار مشتق‌های جزئی $G(h, D)$ نسبت به وزن‌های مختلف شبکه که فرضیه‌ی h را مشخص می‌کند ایجاد می‌شود (برای توضیح کامل درباره‌ی جزئیات جستجوی شیب نزول و واژگان بکار رفته به فصل ۴ مراجعه کنید). در این قسمت، مشتق جزئی $G(h, D)$ نسبت به وزن w_{jk} که از واحد k ام به واحد j ام است به فرم زیر است:

¹ cross entropy

² weight training

$$\begin{aligned}
 \frac{\partial G(h, D)}{\partial w_{jk}} &= \sum_{i=1}^m \frac{\partial G(h, D)}{\partial h(x_i)} \frac{\partial h(x_i)}{\partial w_{jk}} \\
 &= \sum_{i=1}^m \frac{\partial (d_i \ln h(x_i) + (1 - d_i) \ln(1 - h(x_i)))}{\partial h(x_i)} \frac{\partial h(x_i)}{\partial w_{jk}} \\
 &= \sum_{i=1}^m \frac{d_i - h(x_i)}{\partial h(x_i)(1 - h(x_i))} \frac{\partial h(x_i)}{\partial w_{jk}}
 \end{aligned} \tag{6.14}$$

برای ساده نگه داشتن محاسبات، فرض کنید که شبکه‌ی عصبی ما از یک لایه واحد سیگموئید تشکیل شده و در این حالت داریم که

$$\frac{\partial h(x_i)}{\partial w_{jk}} = \sigma'(x') x_{ijk} = h(x_i)(1 - h(x_i)) x_{ijk}$$

در این رابطه x_{ijk} ، آمین ورودی به واحد j برای i آمین نمونه‌ی آموزشی است، و $\sigma'(x)$ مشتق تابع سیگموئید است (به فصل ۴ رجوع کنید).
 بالاخره، این رابطه را در رابطه‌ی ۶.۱۴ جایگذاری می‌کنیم و رابطه‌ی برای مؤلفه‌های گرادیان بدست می‌آوریم،

$$\frac{\partial G(h, D)}{\partial w_{jk}} = \sum_{i=1}^m (d_i - h(x_i)) x_{ijk}$$

چون بیشتر به دنبال ماکزیمم $P(D|h)$ هستیم تا مینیمم به جای شیب نزول از جستجوی شیب صعود^۱ استفاده می‌کنیم. در هر حلقه جستجو برادر توسط قانون زیر به سمت گرادیان تصحیح می‌شود.

$$w_{jk} \leftarrow w_{jk} + \Delta w_{jk}$$

که داریم،

$$\Delta w_{jk} = \eta \sum_{i=1}^m (d_i - h(x_i)) x_{ijk} \tag{6.15}$$

و در این رابطه نیز η مقدار کوچک و مثبت است که اندازه‌ی قدم‌ها در جستجوی شیب صعود را مشخص می‌کند.

جالب است که این قانون تغییر وزن‌ها را با قانون تغییر وزن الگوریتم Backpropagation که مجموع خطای مربعی بین پیش بینی و مقدار اصلی را مینیمم می‌کرد مقایسه کنیم. قانون تغییر وزن برای واحد‌های خروجی در Backpropagation با نشانه گذاری این فصل به شکل زیر است،

$$w_{jk} \leftarrow w_{jk} + \Delta w_{jk}$$

¹ gradient ascent

که در آن

$$\Delta w_{jk} = \eta \sum_{i=1}^m h(x_i)(1 - h(x_i))(d_i - h(x_i))x_{ijk}$$

توجه دارید که این رابطه جز در جمله‌ی $h(x_i)(1 - h(x_i))$ که از تابع سیگموئید ناشی شده کاملاً شبیه رابطه‌ی ۶.۱۵ است.

خلاصه اینکه، این دو قانون تغییر وزن هر دو در تعریف مسئله‌ی خودشان به سمت محتمل‌ترین فرضیه همگرا می‌شوند. قانونی که مجموع خطاهای مربعی را مینیمم می‌کند با فرض اینکه خطاهای داده‌های آموزشی را می‌توان با توزیع نرمال مدل سازی کرد به دنبال محتمل‌ترین فرضیه می‌گردد. قانونی که آنتروپی دورگه را مینیمم می‌کند با فرض اینکه مقادیر منطقی مشاهده شده احتمالی (و نه قطعی) هستند به دنبال محتمل‌ترین فرضیه برای تابع پیش بینی احتمال بر حسب نمونه‌ها می‌گردد.

۶.۶ قانون کمترین طول توضیح^۱

با توجه به آنچه در فصل ۳ درباره‌ی تیغ Ocam گفته شد، یک بایاس استقرایی متداول، به فرم "توضیحی که کوتاه تر است را در مورد داده‌های مشاهده شده قبول کن" است. در آن فصل درباره‌ی ضررهای توضیحات بلند با توجه به تیغ Ocam استدلال کردیم. در اینجا با دیدی بیزی به این موضوع می‌پردازیم و قانونی مشابه به نام قانون کمترین طول توضیح (MDL) را بررسی خواهیم کرد.

انگیزه‌ی ایجاد قانون کمترین طول توضیح تفسیر تعریف h_{MAP} با مفاهیم اولیه‌ی تئوری اطلاعات است. دوباره تعریف نه چندان ناآشنای h_{MAP} را به خاطر بیاورید.

$$h_{MAP} = \arg \max_{h \in H} P(D|h)P(h)$$

این رابطه را می‌توان به صورت معادل با $\log_2$ آن نیز نشان داد،

$$h_{MAP} = \arg \min_{h \in H} -\log_2 P(D|h) - \log_2 P(h) \quad (6.16)$$

جالب است که رابطه‌ی ۶.۱۶ را می‌توان طوری تفسیر کرد که فرضیه‌های کوتاه‌تر ارجح‌ترند، با فرض اینکه یک طرح نمایش خاص برای کد کردن فرضیه‌ها و داده‌ها استفاده کنیم. برای توضیح این، بیایید ابتدا یک نتیجه‌ی اساسی تئوری اطلاعات را معرفی کنیم: مسئله‌ی طراحی کدی برای ارسال پیام‌های تصادفی، را که در آن احتمال ارسال پیام i مقدار p_i است را در نظر بگیرید. در اینجا علاقه‌ی ما به فشردن‌ترین کد ممکن است؛ به عبارت دیگر علاقه‌ی ما به کدی است که امید تعداد بیت‌هایی که باید ارسال شوند تا یک پیام تصادفی فرستاده شود مینیمم کند. واضح است که برای مینیمم کردن امید طول کد ارسالی باید کدهای کوتاه‌تر را به پیام‌هایی اختصاص دهیم که احتمال بیشتری دارند. (Shannon and Weaver 1949) نشان دادند که کد بهینه (کدی که امید تعداد بیت‌های ارسالی را مینیمم می‌کند) به پیام i ، $\log_2 p_i$ بیت برای کد کردن اختصاص می‌دهد. به این تعداد بیت که برای کد کردن پیام i توسط کد C لازم است طول توضیح پیام i بر اساس C نیز می‌گویند و با $L_C(i)$ آنرا نشان می‌دهند.

¹ Minimum description length

بیاپید حالا رابطه‌ی ۶.۱۶ را با توجه به نتیجه‌ی بالا از تئوری کد سازی بررسی کنیم.

- $-\log_2 P(h)$ اندازه‌ی توضیح h بر اساس کد بهینه‌ی تمامی فضای فرضیه‌ی H است. به عبارت دیگر، این مقدار اندازه‌ی توضیحات فرضیه‌ی h با استفاده از نمایش بهینه است. در نماد گذاری فعلی $L_{C_H}(h) = -\log_2 P(h)$ ، که در آن C_H کد بهینه برای کد کردن فضای فرضیه‌ی H است.
- $-\log_2 P(D|h)$ اندازه‌ی توضیح داده‌های آموزشی D با معلوم بودن h توسط کد بهینه است. در نماد گذاری فعلی $L_{C_{D|h}}(D|h) = -\log_2 P(D|h)$ ، که در آن $C_{D|h}$ کد بهینه برای توضیح داده‌های D با فرض اینکه فرستنده و گیرنده هر دو مطلع از h هستند است.
- بنابراین می‌توانیم رابطه‌ی ۶.۱۶ را برای تعریف h_{MAP} بازنویسی کنیم و بگوییم h_{MAP} فرضیه‌ی h است که مجموع طول توضیحات فرضیه‌ها به علاوه‌ی طول توضیحات داده‌ها با معلوم بودن فرضیه را مینیمم می‌کند.

$$h_{MAP} = \arg \min_h L_{C_H}(h) + L_{C_{D|h}}(D|h)$$

در این رابطه C_H و $C_{D|h}$ به ترتیب کدهای بهینه برای H و D با معلوم بودن h هستند.

قانون کمترین طول توضیح (MDL) توصیه می‌کند که فرضیه‌هایی را انتخاب کنیم که مجموع این دو طول توضیح را حداقل کنند. البته برای بکار بردن این قانون در عمل باید کد سازی یا نمایش خاصی را که با عمل یادگیری متناسب است انتخاب کنیم. با فرض اینکه ما از کدهای C_1 و C_2 برای نمایش فرضیه‌ها و داده‌ها با معلوم بودن فرضیه استفاده می‌کنیم، می‌توان MDL را به صورت زیر بیان کرد،

قانون کمترین طول توضیح: فرضیه‌ی h_{MDL} را انتخاب کن،

$$h_{MDL} = \arg \min_{h \in H} L_{C_1}(h) + L_{C_2}(D|h) \quad (6.17)$$

بررسی بالا نشان می‌دهد که اگر ما C_1 را برای کد سازی بهینه‌ی فرضیه‌ها، C_H و C_2 را برای کد سازی بهینه‌ی داده‌ها، $C_{D|h}$ ، انتخاب کنیم داریم $h_{MDL} = H_{MAP}$.

به صورت مفهومی، می‌توان به قانون MDL به فرم ترجیح متدهای کوتاه‌تر برای کد سازی دوباره‌ی داده‌های آموزشی نگاه کرد که در آن هر دو معیار اندازه‌ی فرضیه و هزینه‌ی اضافی کد سازی داده‌ها به شرط معلوم بودن فرضیه در نظر گرفته می‌شود.

بیاپید مثالی را در نظر بگیریم. فرض کنید قصد داریم از قانون MDL برای مسئله‌ی یادگیری درخت‌های تصمیم از داده‌های آموزشی‌ای استفاده کنیم. برای نمایش فرضیه C_1 و داده‌های C_2 چه نمایشی را باید در نظر بگیریم؟ برای C_1 می‌توان به طور طبیعی یکی از کد سازی‌های واضح درخت تصمیم، که در آن طول توضیح با افزایش تعداد گره‌های درخت و تعداد یال‌ها افزایش می‌یابد را انتخاب کرد. اما چگونه باید با معلوم بودن یک درخت فرضیه‌ی خاص مجموعه‌ی داده‌های C_1 را کد کرد. برای ساده نگه داشتن موضوع، فرض کنید که سری نمونه‌های $\langle x_1 \dots x_n \rangle$ برای فرستنده و گیرنده معلوم باشد، پس تنها چیز باقیمانده برای ارسال دسته بندی‌های $\langle f(x_1) \dots f(x_n) \rangle$ است. (توجه دارید که هزینه‌ی ارسال خود نمونه‌ها از درستی فرضیه مستقل است، پس به هر حال تأثیری بر انتخاب h_{MDL} ندارد). حال اگر دسته بندی‌های $\langle f(x_1) \dots f(x_n) \rangle$ همان پیش بینی‌های فرضیه باشد، دیگر نیازی به ارسال اطلاعات در مورد نمونه‌ها نیست (گیرنده می‌تواند این مقادیر را با فرضیه‌ی ای که دریافت کرده محاسبه کند). پس بنابراین طول توضیحات لازم

با داشتن فرضیه در این حالت صفر است. در چنین شرایطی اگر نمونه‌هایی توسط h اشتباه دسته بندی شده باشند، لازم است پیغامی مبنی بر دسته بندی اشتباه این نمونه‌ها (طول این پیغام حداکثر $\log_2 n$ بیت خواهد بود) را به همراه دسته بندی درست آن‌ها ارسال کنیم (این کار را می‌توان با پیغامی با حداکثر طول $\log_2 k$ انجام داد که در آن k تعداد دسته بندی‌های ممکن هر نمونه است). در چنین شرایطی فرضیه‌ی h_{MDL} تحت کد سازی C_1 و C_2 فرضیه ای است که کمترین مجموع طول توضیح را لازم داشته باشد.

بنابراین قانون MDL راهی برای ارزیابی پیچیدگی فرضیه‌ها با تعداد اشتباه‌های فرضیه ارائه می‌کند. ممکن است این معیار فرضیه ای کوتاه‌تر را که اشتباهات کمی دارد را نسبت به یک فرضیه بلند تر که اشتباهی ندارد ترجیح دهد. MDL از این نظر، متدی مناسب برای برخورد با مسئله‌ی overfit است.

(Quinlar and Rivest 1989) آزمایشاتی را با استفاده از قانون MDL برای تشخیص بهترین اندازه‌ی درخت تصمیم انجام داده‌اند. آن‌ها گزارش داده‌اند که متد مبتنی بر MDL درخت‌هایی را ایجاد می‌کند که دقتی قابل مقایسه با درخت‌های خروجی الگوریتم‌های فصل ۳ دارند. (Mehta et al. 1995) نیز روش دیگری مبتنی بر MDL برای هرس درخت تصمیم ارائه می‌کند و آزمایش‌هایی را تشریح کرده که در آن روش مبتنی بر MDL نتایج قابل مقایسه ای با روش‌های معمول را می‌دهد.

چه نتیجه گیری‌ای را باید از بررسی قانون کمترین طول توضیح بگیریم؟ آیا این اثباتی بر این که تمامی فرضیه‌های کوتاه‌تر ارجحند است؟ خیر. بلکه ما اثبات کردیم که اگر نمایش فرضیه طوری انتخاب شود که کد سازی فرضیه‌ی h ، $-\log_2 P(h)$ باشد و اگر کد سازی استثنا به گونه ای باشد که طول کد D با شرط معلوم بود h ، $-\log_2 P(h|D)$ ، آنگاه قانون MDL فرضیه ای MAP خروجی خواهد داد. با این وجود، برای نشان دادن برقراری چنین شرطی باید تمامی احتمالات اولیه‌ی $P(h)$ و $P(D|h)$ را داشته باشیم. هیچ دلیلی برای این وجود ندارد که باور داشته باشیم که MDL برای هر کد سازی دلخواه C_1 و C_2 بر قرار است. ممکن گاهی برای طراح انسانی مشخص کردن نمایشی خاص برای دانش در مورد احتمالات نسبی فرضیه‌ها راحت‌تر از نمایش کامل احتمال دقیق هر یک از فرضیه‌ها باشد. توصیفات به کار رفته در ادبیات کاربرد MDL در مسائل یادگیری کاربردی گاهی شامل معیارهایی می‌شود که فرم خاصی از کد سازی C_1 و C_2 را توجیه می‌کند.

۶.۷ دسته بندی کننده‌ی بهینه‌ی بیز^۱

تا اینجا به سؤال "محتمل‌ترین فرضیه با داشتن داده‌های آموزشی کدام است؟" پرداختیم، در واقع، این سؤال بیشتر شبیه این سؤال است که "محتمل‌ترین دسته بندی کننده نمونه‌های جدید با داشتن داده‌های آموزشی کدام است؟". با وجود اینکه ممکن است به نظر برسد که این سؤال دوم را می‌توان با اعمال فرضیه‌ی MAP به نمونه‌های جدید جواب داد، کاری بهتر ممکن است.

برای ایجاد شهود فضای فرضیه ای را در نظر بگیرید که سه فرضیه‌ی h_1 ، h_2 و h_3 را شامل می‌شود. فرض کنید که احتمال ثانویه‌ی این فرضیه با داده‌های آموزشی به ترتیب ۴ و ۳ و ۳ است. بنابراین، h_1 فرضیه‌ی MAP است. حال فرض کنید که نمونه‌ی جدید X به ما داده می‌شود که توسط h_1 مثبت و توسط دو فرضیه‌ی h_2 و h_3 منفی دسته بندی می‌شود. با در نظر گرفتن تمامی فرضیه‌ها نمونه‌ی X به احتمال ۴ مثبت است (احتمال مربوط به فرضیه‌ی h_1)، و به احتمال ۶ منفی است. محتمل‌ترین دسته بندی (منفی) در این مثال با دسته بندی MAP متفاوت است.

¹ bayes optimal classifier

در کل محتمل ترین دسته بندی نمونه‌ی جدید از ترکیب پیش بینی‌های همه‌ی فرضیه‌ها بدست می‌آید، فقط هر فرضیه به اندازه‌ی احتمال ثانویه‌اش در این دسته بندی تأثیر گذار است. اگر دسته بندی ممکن نمونه‌ی جدید v_j عضو مجموعه‌ی V باشد، $P(v_j|D)$ احتمال اینکه دسته بندی v_j برای نمونه‌ی جدید درست باشد به صورت زیر است،

$$P(v_j|D) = \sum_{h_i \in H} P(v_j|h_i)P(h_i|D)$$

دسته بندی ی بهینه‌ی نمونه‌ی جدید مقدار v_j است که با آن $P(v_j|D)$ ماکزیمم می شود،

دسته بندی ی بهینه‌ی بیز:

$$\arg \max_{v_j \in V} \sum_{h_i \in H} P(v_j|h_i)P(h_i|D) \quad (6.18)$$

برای شهود در مثال بالا، مجموعه‌ی دسته بندی‌های نمونه‌ی جدید $V = \{\oplus, \ominus\}$ است و

$$P(h_1|D) = .4, P(\ominus |h_1) = 0, P(\oplus |h_1) = 1$$

$$P(h_2|D) = .3, P(\ominus |h_2) = 1, P(\oplus |h_2) = 0$$

$$P(h_3|D) = .3, P(\ominus |h_3) = 1, P(\oplus |h_3) = 0$$

بنابراین،

$$\sum_{h_i \in H} P(\oplus |h_i)P(h_i|D) = .4$$

$$\sum_{h_i \in H} P(\ominus |h_i)P(h_i|D) = .6$$

9

$$\arg \max_{v_j \in \{\oplus, \ominus\}} \sum_{h_i \in H} P(v_j|h_i)P(h_i|D) = \ominus$$

هر سیستمی که نمونه‌های جدید را با رابطه‌ی ۶.۱۸ دسته بندی کند دسته بندی کننده‌ی بهینه‌ی بیز^۱ یا یادگیر بهینه‌ی بیز^۲ نامیده می‌شود. هیچ متد دسته بندی دیگری با همان فضای فرضیه ای و همان دانش اولیه نمی‌تواند به طور متوسط بازده بهتری داشته باشد. این متد احتمال اینکه نمونه‌ی جدید درست دسته بندی شود را با معلوم بودن داده‌های موجود و فضای فرضیه ای احتمالات اولیه‌ی فرضیه‌ها حداکثر می‌کند.

¹ Bayes optimal classifier

² Bayes optimal learner

برای مثال در یادگیری مفاهیم حقیقی مقدار با استفاده از فضای ویژه، همان طور که در قسمت قبلی هم گفته شد، دسته بندی بهینه‌ی بیز نمونه های جدید با دادن وزن (احتمال ثانویه‌ی فرضیه) و رای گیری بین اعضای فضای ویژه انجام می‌گرفت.

یکی از ویژگی‌های عجیب دسته بندی کننده‌ی بهینه‌ی بیز این است که پیش بینی‌هایی که انجام می‌دهد ممکن است فرضیه ای را تشکیل دهد که حتی در H موجود نیست. تصور کنید که از رابطه‌ی ۶.۱۸ برای دسته بندی تمامی نمونه های X استفاده کرده‌ایم. این دسته بندی نمونه‌ها که بدین صورت تعریف می‌شود الزاماً با فرضیه ای مثل h در H سازگار نیست. یکی از روش‌های نگاه به این وضعیت تصور دسته بندی کننده بهینه‌ی بیز به عنوان عاملی است که فضای فرضیه ای H' را به طرز موثری، که با فضای فرضیه ای H (که قضیه بیز روی آن اعمال شده) فرق دارد، در نظر می‌گیرد. در کل، H' به صورت موثر فرضیه‌هایی که مقایسه ای خطی بین ترکیبات پیش بینی‌های فرضیه های مختلف H می‌کنند را شامل می‌شود.

۶.۸ الگوریتم گیبس

با وجود اینکه دسته بندی کننده‌ی بهینه‌ی بیز بهترین عملکرد ممکن را با داشتن داده های آموزشی دارد، اما اعمال آن هزینه بر است. این هزینه در محاسبه‌ی احتمال ثانویه‌ی تمامی فرضیه های H و ترکیب پیش بینی‌هایشان برای هر نمونه‌ی جدید است.

یک روش جایگزین، ولی کمتر بهینه الگوریتم گیبس (رجوع کنید به (Oppor and Haussler 1991) است، که به صورت زیر تعریف می‌شود:

۱. فرضیه ای مثل h از H به طور تصادفی و با توزیع احتمالات ثانویه انتخاب کن.
 ۲. از h برای دسته بندی نمونه‌ی جدید بعدی استفاده کن.
- زمانی که نمونه‌ی جدیدی برای دسته بندی ارائه می‌شود، الگوریتم گیبس به سادگی فرضیه ای به طور تصادفی و با توزیع احتمالات ثانویه انتخاب می‌کند و دسته بندی آن‌را به عنوان خروجی می‌دهد. جالب‌تر اینکه، می‌توان نشان داد که در شرایطی امید تعداد دسته بندی‌های غلط این الگوریتم حداکثر دو برابر امید خطای دسته بندی کننده‌ی بهینه‌ی بیز است (Haussler 1994). به عبارت دقیق‌تر، مقدار امید برای تمامی مفاهیم هدف تصادفی و توزیع احتمال اولیه‌ی یادگیر محاسبه شده. در چنین شرایطی، مقدار امید خطای الگوریتم گیبس دو برابر بدتر از مقدار امید خطای دسته بندی کننده‌ی بهینه‌ی بیز است.

این نتیجه معنای جالبی در مسائل یادگیری مفهوم که قبلاً در موردشان بحث کردیم دارد. در کل، این نتیجه نشان می‌دهد که اگر یادگیر احتمالات اولیه H را یکسان فرض کند، و مفاهیم هدف نیز در واقع با چنین احتمالی انتخاب شوند، آنگاه دسته بندی نمونه‌ی بعدی با فرضیه ای که به طور تصادفی از فضای ویژه انتخاب می‌شود (با توزیعی یکنواخت)، حداکثر دو برابر امید خطای دسته بندی کننده‌ی بهینه‌ی بیز، امید خطا خواهد داشت. دوباره، با نمونه ای از بررسی بیزی یک الگوریتم غیر بیزی طرف هستیم که این بررسی میزان کارایی آن الگوریتم را مشخص می‌کند.

۶.۹ دسته بندی کننده ی بیز

یکی از متدهای پر کاربرد یادگیری بیزی، یادگیر ساده ی بیز^۱ است که معمولاً دسته بندی کننده ی ساده ی بیز^۲ نیز نامیده می شود. در بعضی کاربردها کارایی این متد قابل مقایسه با شبکه های عصبی و یادگیری درختی است. در این بخش دسته بندی کننده ی ساده ی بیز را مورد بحث و بررسی قرار می دهیم و در بخش بعدی آن را در مسئله یادگیری ای واقعی دسته بندی متون زبان های طبیعی به کار می بریم.

دسته بندی کننده ی ساده ی بیز در کار های یادگیری ای به کار می رود که در آن X با عطفی از مقادیر ویژگی ها مشخص می شود و تابع هدف $f(x)$ می تواند هر مقدار از مجموعه ی V باشد. مجموعه ای از نمونه های آموزشی تابع هدف و نمونه ای جدید که با ویژگی هایش توصیف شده به یادگیر داده می شود، $\langle a_1, a_2 \dots a_n \rangle$ و از آن خواسته می شود که مقدار تابع هدف یا دسته بندی تابع هدف را برای این نمونه ی جدید پیش بینی کند.

روش بیزی برای دسته بندی نمونه ی جدید، دسته بندی آن بر اساس محتمل ترین مقدار تابع هدف، v_{MAP} است با داشتن نمونه های $\langle a_1, a_2 \dots a_n \rangle$ است.

$$v_{MAP} = \arg \max_{v_j \in V} P(v_j | a_1, a_2 \dots a_n)$$

با استفاده از قضیه ی بیز این رابطه را بازنویسی می کنیم،

$$\begin{aligned} v_{MAP} &= \arg \max_{v_j \in V} \frac{P(a_1, a_2 \dots a_n | v_j) P(v_j)}{P(a_1, a_2 \dots a_n)} \\ &= \arg \max_{v_j \in V} P(a_1, a_2 \dots a_n | v_j) P(v_j) \end{aligned} \quad (6.19)$$

حال می توانیم دو عبارت رابطه ی ۶.۱۹ را بر اساس داده های آموزشی تخمین بزنیم. تخمین مقادیر $P(v_j)$ با شمارش تعداد تکرار مقدار های ویژگی هدف در بین داده های آموزشی بسیار ساده است. با این وجود، تخمین عبارتی با فرم $P(a_1, a_2 \dots a_n | v_j)$ بدین صورت ممکن نیست، مگر اینکه مجموعه ی داده های آموزشی مان بسیار بزرگ باشد. مشکل اینجاست که تعداد این چنین عبارت هایی مساوی تعداد نمونه های ممکن ضربدر تعداد مقادیر ممکن تابع هدف است. بنابراین لازم است که هر نمونه ممکن در فضای نمونه ای چندین بار مشاهده شود تا تخمین احتمال قابل اطمینان باشد.

دسته بندی کننده ی ساده ی بیز بر اساس یک فرض ساده سازی است، مقدار ویژگی ها با معلوم بودن مقدار هدف مستقلند. به عبارت دیگر، فرض هایی که با داشتن مقدار هدف نمونه می توان زد، احتمال مشاهده ی عطف $a_1, a_2 \dots a_n$ فقط وابسته به احتمال تک تک این نمونه هاست: $P(a_1, a_2 \dots a_n | v_j) = \prod_i P(a_i | v_j)$. با جایگذاری این رابطه در رابطه ی ۶.۱۹ به دسته بندی کننده ی ساده ی بیز می رسیم.

دسته بندی کننده ی ساده بیز:

¹ Naïve bayes learner

² Naïve bayes classifier

$$v_{NB} = \arg \max_{v_j \in V} P(v_j) \prod_i P(a_i | v_j) \quad (6.20)$$

در این رابطه v_{NB} نماد مقدار هدفی خروجی دسته بندی کننده‌ی ساده‌ی بیز است. توجه دارید که در یک دسته بندی کننده‌ی ساده‌ی بیز تعداد جملات متمایز $P(a_i | v_j)$ موجود، که باید بر اساس داده‌های آموزشی تخمین زده شود، ضرب تعداد مقادیر ویژگی‌ها و تعداد مقادیر هدف است، این عدد در نگاه اول، نسبت به تعداد جملات ممکن $P(a_1, a_2 \dots a_b | v_j)$ بسیار کوچکتر است.

به طور خلاصه، متد یادگیری ساده‌ی بیز مرحله‌ای دارد که در آن جملات مختلف $P(a_i | v_j)$ و $P(v_j)$ بر اساس تعداد تکرارشان در میان نمونه‌های آموزشی تخمین زده می‌شوند. مجموعه‌ی این تخمین‌ها تعیین کننده‌ی فرضیه‌ی تخمینی خواهد بود. این فرضیه، برای دسته بندی نمونه‌های جدید رابطه‌ی ۶.۲۰ را بکار خواهد بست. هرگاه که فرض استقلال شرطی ارضا می‌شود، و دسته بندی ساده‌ی بیز v_{NB} همان دسته بندی MAP خواهد بود.

یکی از تفاوت‌های جالب دسته بندی کننده‌ی ساده‌ی بیز و دیگر متد‌های یادگیری بحث شده، این است که این روش جستجویی صریح در میان فرضیه‌های ممکن انجام نمی‌دهد (در چنین شرایطی، فضای فرضیه‌ها همان فضای مقادیر ممکن قابل نسبت به متغیر $P(v_j)$ و $P(a_i | v_j)$ است). در مقابل، فرضیه‌ها بدون جستجو و فقط با شمارش تعداد تکرار ترکیب‌های مختلف داده در میان نمونه‌های آموزشی ایجاد می‌شوند.

۶.۹.۱ مثالی توضیحی

بیایید دسته بندی کننده‌ی ساده‌ی بیز را به مسئله یادگیری مفهومی که در فصل یادگیری درختی مطرح شد بکار ببریم: دسته بندی روزها بر اساس اینکه کسی تنیس بازی خواهد کرد یا خیر. جدول ۳.۲ مجموعه‌ای از ۱۴ نمونه‌ی آموزشی را برای مفهوم PlayTennis نشان می‌دهد، در اینجا روزها با ویژگی‌های Outlook, Temperature, Humidity, و Wind توصیف می‌شوند. در اینجا از دسته بندی کننده‌ی ساده‌ی بیز و داده‌های آموزشی این جدول برای دسته بندی نمونه‌ی جدید زیر استفاده می‌کنیم:

<Outlook=sunny, Temperature=cool, Humidity=high, Wind=strong>

هدف در اینجا پیش بینی مقدار هدف (Yes یا No) مفهوم هدف PlayTennis برای نمونه‌ی جدید است. با مقدار گذاری رابطه‌ی ۶.۲۰ برای این کار مقدار v_{NB} به صورت زیر محاسبه می‌شود.

$$\begin{aligned} v_{NB} &= \arg \max_{v_j \in \{yes, no\}} P(v_j) \prod_i P(a_i | v_j) \\ &= \arg \max_{v_j \in \{yes, no\}} P(v_j) P(\text{Outlook} = \text{sunny} | v_j) P(\text{Temperature} = \text{cool} | v_j) \\ &\quad P(\text{Humidity} = \text{High} | v_j) P(\text{Wind} = \text{strong} | v_j) \end{aligned} \quad (6.21)$$

توجه دارید که در عبارت آخری a_i با استفاده از مقادیر ویژگی‌های نمونه‌ی جدید نوشته شده است. برای محاسبه‌ی v_{NB} به ۱۰ احتمال نیاز داریم که از روی داده‌های آموزشی تخمین زده می‌شوند. ابتدا، احتمال مقادیر مختلف هدف، که می‌توان آن‌را به سادگی با شمارش تکرار مقادیر از نمونه‌های آموزشی استخراج کرد.

$$P(\text{PlayTennis} = \text{yes}) = \frac{9}{14} = .64$$

$$P(\text{PlayTennis} = \text{no}) = \frac{5}{14} = .36$$

به طور مشابه می توان احتمالات شرطی را تخمین زد. برای مثال، برای Wind = strong داریم،

$$P(\text{Wind} = \text{strong} | \text{PlayTennis} = \text{yes}) = \frac{3}{9} = .33$$

$$P(\text{Wind} = \text{strong} | \text{PlayTennis} = \text{no}) = \frac{3}{5} = .60$$

با استفاده از تخمین های احتمالات مذکور و تخمین مشابه دیگر ویژگی ها، v_{NB} را بر اساس رابطه ی ۶.۲۱ به صورت زیر محاسبه می کنیم،

$$P(\text{yes}) P(\text{sunny} | \text{yes}) P(\text{cool} | \text{yes}) P(\text{high} | \text{yes}) P(\text{strong} | \text{yes}) = .0053$$

$$P(\text{no}) P(\text{sunny} | \text{no}) P(\text{cool} | \text{no}) P(\text{high} | \text{no}) P(\text{strong} | \text{no}) = .0053$$

دسته بندی کننده ی ساده ی بیز احتمالات تخمینی بر اساس داده های آموزشی موجود مقدار $\text{PlayTennis} = \text{no}$ را به این نمونه ی جدید اختصاص می دهد. علاوه بر این، با نرمالیزه کردن کمیت های بالا (طوری که جمعشان یک شود) می توان احتمال شرطی اینکه مقدار تابع هدف no باشد را حساب کرد. برای مثال فعلی، این احتمال مقدار $.795 = \frac{.0206}{.0206 + .0053}$ است.

۶.۹.۱.۱ تخمین احتمالات

تا به حال، احتمالات را با نسبت تعداد مشاهدی اتفاق به کل حالات را تخمین زدیم. برای مثال، در مثال بالا مقدار $P(\text{Wind} = \text{strong} | \text{PlayTennis} = \text{no})$ را با نسبت $\frac{n_c}{n}$ تخمین زدیم، در این نسبت $n=5$ تعداد نمونه های آموزشی $\text{PlayTennis} = \text{no}$ و $n_c = 3$ تعداد نمونه هایی بود که در آن Wind=strong بود.

با وجود اینکه در بسیاری از موارد این نسبت تخمین خوبی از احتمال به ما می دهد، اما زمانی که n_c بسیار کوچک است تخمین ضعیف خواهد بود. برای درک این مشکل، فرض کنید که در حقیقت مقدار احتمال $P(\text{Wind} = \text{strong} | \text{PlayTennis} = \text{no})$ برابر با 0.8 باشد و در مجموعه ی نمونه های ما فقط ۵ نمونه مقدار $\text{PlayTennis} = \text{no}$ را داشته باشند. با این فرض ها، n_c به احتمال زیادی صفر خواهد بود. این حقیقت دو مشکل ایجاد می کند. ابتدا اینکه $\frac{n_c}{n}$ تخمینی بایاس دار و دست کم گیرنده از مقدار احتمال خواهد بود. دوم اینکه زمانی که تخمین این احتمال صفر است باعث می شود که تمامی نمونه هایی که در آن ها Wind=strong است جزو دسته ی دیگر اطلاق شوند.

برای پرهیز از این مشکل می توان از روش بیزی برای تخمین احتمالات استفاده کرد، برای این کار تخمین m^1 را به فرم زیر تعریف می کنیم.

تخمین m احتمالات:

¹ m-estimate

$$\frac{n_c + mp}{n + m} \quad (6.22)$$

در این رابطه n_c و n همان مقادیر رابطه‌ی قبلی‌اند و p احتمال اولیه‌ی مقدار تخمینی است. m ثابتی که اندازه‌ی نمونه‌ی معادل¹ نامیده می‌شود. این ثابت مشخص می‌کند که مقدار احتمال به چه میزان به نمونه‌های آموزشی وابسته باشد. یکی از روش‌های متداول انتخاب p بدون داشتن هیچ اطلاعات قبلی‌ای، یکنواخت گرفتن تمامی احتمالات اولیه است؛ بدین معنا که اگر ویژگی‌ای k مقدار ممکن دارد خواهیم داشت که $p = \frac{1}{k}$. برای مثال، در تخمین $P(\text{Wind=strong} | \text{PlayTennis=no})$ می‌دانیم که ویژگی Wind دو مقدار ممکن دارد، پس با احتمال اولیه‌ی یکنواخت خواهیم داشت که $p=0.5$. توجه دارید که اگر m را صفر انتخاب کنیم، تخمین m معادل همان کسر ساده‌ی $\frac{n_c}{n}$ می‌شود. اگر مقادیر m و n هر دو غیر صفر باشند، حاصل تخمین m میانگین دو مقدار با وزن m خواهد بود. m ثابت اندازه‌ی نمونه‌ی معادل نامیده می‌شود از این رو که رابطه‌ی ۶.۲۲ را می‌توان به صورت ترکیب n مشاهده‌ی واقعی و m مشاهده‌ی مجازی (با احتمال p) در نظر گرفت.

۶.۱۰ یک مثال: یادگیری دسته بندی متون

برای تصور اهمیت کاربردی متدهای یادگیری بیز، مسئله‌ی یادگیری‌ای را در نظر بگیرید که در آن نمونه‌ها متنند. برای مثال، شاید بخواهیم مفهوم هدف "مقالات خبری الکترونیکی جالب برای من" یا "صفحاتی از Web که یادگیری ماشین در آن‌ها بحث شده" را یاد بگیریم. در هر دو حالت، اگر یک کامپیوتر بتواند چنین کاری را انجام دهد می‌تواند به جای تعداد بسیاری زیادی از متون وب فقط مربوطترین نتیجه جستجو روی وب را به کاربر ارائه کند.

در اینجا الگوریتمی کلی بر اساس دسته بندی کننده‌ی ساده‌ی بیز برای یادگیری دسته بندی متون ارائه می‌کنیم. جالب است که روش‌های احتمالی مثل آنچه پیش‌تر توضیح دادیم یکی از مؤثرترین الگوریتم‌های شناخته شده برای دسته بندی متون هستند. مثال‌هایی از چنین سیستم‌هایی در (Lewis 1991)، (Lang 1995) و (Joachims 1996) توصیف شده‌اند.

الگوریتم دسته بندی کننده‌ی ساده بیز که توضیح خواهیم داد با تعریف مسئله‌ی کلی تطابق دارد. فضای نمونه‌ی X را که شامل تمامی مستندات متنی (تمامی رشته کلمات و علامات با طول دلخواه) است در نظر بگیرید. به ما نمونه‌های آموزشی تابع هدف مجهول $f(x)$ داده شده است، این تابع مجهول ممکن است هر یک از اعضای V باشد. هدف ما یادگیری از این نمونه‌های آموزشی برای پیش بینی مقدار هدف متنی جدید است. برای تصور، تابع هدف دسته بندی متون به دو دسته‌ی جذاب و غیر جذاب برای فرد بخصوص است، برای این تابع هدف مقادیر like (جذاب) و dislike (غیر جذاب) برای دسته بندی این دو مجموعه تعریف می‌شود.

دو مشکل اصلی برای کاربرد دسته بندی کننده‌ی ساده‌ی بیز در مسائل دسته بندی متن وجود دارد. اول اینکه با چه روشی یک متن دلخواه را با مقدار ویژگی‌هایی نمایش داد و دوم اینکه احتمالات لازم برای دسته بندی کننده‌ی ساده‌ی بیز را با چه روشی تخمین زد.

روش ما در نمایش متن دلخواه به طرز مشکل سازی ساده است: با داشتن یک متن، مثل همین پاراگراف، باید یک ویژگی برای هر مکان کلمه در متن تعریف کنیم و مقدار ویژگی‌ها را هم کلمات آن مکان‌ها در نظر بگیریم. بنابراین این پاراگراف ۹۷ مقدار ویژگی خواهد داشت که متناسب

¹ equivalent sample size

با ۹۷ کلمه‌ی این پاراگراف است. مقدار ویژگی اول کلمه‌ی "روش" و مقدار ویژگی دوم کلمه‌ی "ما" خواهد بود و ... توجه دارید که با این روش متون بلند تعداد بیشتری ویژگی خواهند داشت. همان طور که بعداً نیز خواهیم دید، این تفاوت هیچ مشکلی ایجاد نمی‌کند.

با این نمایش برای متون، حال می‌توانیم دسته بندی کننده‌ی ساده‌ی بیز را به مسئله اعمال کنیم. بیا بید به خاطر حفظ سادگی، فرض کنیم که ۷۰۰ متن آموزشی که فردی dislike دسته بندی کرده به همراه ۳۰۰ متن دیگر که like دسته بندی شده در اختیار است. حال متن جدیدی در اختیار یادگیر قرار گرفته و از وی دسته بندی این متن سؤال می‌شود. دوباره به خاطر سادگی، بیا بید فرض کنیم که متن جدید پاراگراف قبلی باشد. در چنین شرایطی، اگر رابطه‌ی ۶.۲۰ را برای دسته بندی مقدار دهی کنیم خواهیم داشت که،

$$v_{NB} = \arg \max_{v_j \in \{like, dislike\}} P(v_j) \prod_{i=1}^{97} P(a_i | v_j)$$

$$\arg \max_{v_j \in \{like, dislike\}} P(v_j) P(a_1 = \text{"روش"} | v_j) P(a_2 = \text{"ما"} | v_j)$$

$$\dots P(a_{97} = \text{"نمی‌کند"} | v_j)$$

به طور خلاصه، دسته بندی ساده‌ی بیز v_{NB} دسته بندی‌ای است که احتمال مشاهده‌ی کلماتی را که واقعاً در متن بوده‌اند را با توجه به فرض مستقل بودن ساده‌ی بیز ماکزیم می‌کند. فرض مستقل بودن $P(a_1, \dots, a_{97} | v_j) = \prod_{i=1}^{97} P(a_i | v_j)$ در این تعریف مسئله فرض می‌کند که احتمال هر کلمه با داشتن دسته بندی متن v_j ، برای هر مکان در متن مستقل از دیگر کلمات دیگر مکان‌هاست. توجه می‌کنید که این فرض به وضوح غلط است. برای مثال، در متون ممکن است احتمال آمدن کلمه‌ی "ماشین" بعد از کلمه‌ی "یادگیری" بسیار بیشتر از دیگر کلمات باشد. با وجود این نقص مشهود فرض مستقل بودن، انتخاب دیگری جز این نداریم، زیرا که بدون این شرط تعداد جملات احتمالی‌ای که باید محاسبه شوند به شدت زیاد می‌شوند. خوشبختانه در یادگیر ساده‌ی بیز در بسیاری از موارد در مسائل دسته بندی متون بر خلاف غلط بودن فرض استقلال نتایج خوبی بدست می‌آید. (Domingos and Pazzani 1996) بررسی جالبی از این پدیده‌ی تصادفی ارائه می‌کند.

برای محاسبه‌ی v_{NB} با استفاده از رابطه‌ی بالا، نیاز داریم که احتمال جمله‌های $P(v_j)$ و $P(a_i = w_k | v_j)$ را محاسبه کنیم (در این مسئله w_k ، k امین واژه‌ی واژگان زبان فارسی است). احتمالات جمله‌ی اول را می‌توان به سادگی و با یک نسبت ساده از نمونه‌های آموزشی محاسبه کرد، (در مثال فعلی $P(like)=0.3$ و $P(dislike)=0.7$). مثل همیشه تخمین دسته بندی احتمالات شرطی (مثل $P(a_1 = \text{"روش"} | dislike)$) مشکل ساز تر خواهد بود زیرا که باید چنین جمله‌ی احتمالی را برای هر ترکیب از متن ممکن کلمات فارسی و تابع هدف محاسبه کنیم. متأسفانه با 50,000 کلمه در واژگان زبان و ۲ حالت مقادیر هدف و ۹۷ کلمه‌ی نمونه‌ی فعلی به تقریباً محاسبه‌ی $10,000,000 \approx 2.97 \times 50,000$ حالت نیاز خواهیم داشت.

خوشبختانه، می‌توانیم فرض استدلالی دیگری نیز که تعداد احتمالات را کم بکند به فرض‌ها پیشین اضافه کنیم. در کل، می‌توانیم احتمال بر خورد با کلمه‌ی خاص w_k (مثل "شکلات") را مستقل از مکان حضورش (مثل a_{23} یا a_{95}) در نظر بگیریم. به عبارت رسمی‌تر، ویژگی‌ها از هم مستقلند و توزیع یکسان نیز دارند، با معلوم بودن دسته بندی هدف؛ برای تمامی m, k, j, i داریم $P(a_i = w_k | v_j) = P(a_m = w_k | v_j)$ بنابراین تخمین می‌زنیم که کل مجموعه احتمالات $P(a_1 = w_k | v_j)$ ، $P(a_2 = w_k | v_j)$... برابر با یک مقدار مستقل مثبت $P(w_k | v_j)$ باشد، یعنی این مقدار احتمال به مکان کلمه بستگی ندارد. تأثیر این فرض این است که حال فقط نیاز به محاسبه‌ی

250,000 جمله‌ی مستقل به فرم $P(w_k|v_j)$ داریم. این مقدار هنوز زیاد است اما دیگر در حد کنترل است. توجه دارید که در شرایطی که داده‌های آموزشی محدود باشند، مزیت اولیه‌ی این فرض افزایش تعداد نمونه‌های موجود برای تخمین هر یک از احتمالات و متعاقباً دقت دسته‌بندی است.

برای کامل کردن طراحی الگوریتم یادگیریمان، هنوز باید متدی برای تخمین جملات احتمالات پیدا کنیم. از تخمین m ، که در رابطه‌ی ۶.۲۲ آمد، و احتمالات اولیه‌ی یکنواخت و اندازه‌ی واژگان موجود برای $P(w_k, v_j)$ داریم،

$$\frac{n_k + 1}{n + |\text{Vocabulary}|}$$

در این رابطه n کل تعداد کلمات ممکن در نمونه‌های آموزشی است با مقدار تابع هدف v_j است، n_k تعداد تکرار کلمه‌ی w_k در میان n کلمه‌ی ممکن است و $|\text{Vocabulary}|$ نیز تعداد خالص کل کلمات (و دیگر نشانه‌های) موجود در نمونه‌های آموزشی است.

به طور خلاصه اینکه الگوریتم نهایی از دسته‌بندی کننده‌ی ساده‌ی بیز به همراه فرض استقلال کلمات از مکانشان استفاده می‌کند. الگوریتم نهایی در جدول ۶.۲ آورده شده است. توجه می‌کنید که این الگوریتم به نسبت ساده است. در طول یادگیری، زیر روال Learn-Naive-bayes-text تمامی متون آموزشی را برای استخراج تمام کلمات و نشانه‌های موجود در متون بررسی می‌کند و تعداد تکرارشان را در دسته‌بندی‌های مختلف تابع می‌شمرد تا تخمین‌های لازم را بدست آورد. سپس، برای یک متن جدید (که لازم است دسته‌بندی شود) فرآیند Classify-naive-bayes-text با توجه به رابطه‌ی ۶.۲۰ از این تخمین احتمالات برای محاسبه‌ی v_{NB} استفاده می‌کند. توجه دارید که کلمه که در متن جدید ظاهر شده که در متون قبلی نبوده‌اند توسط Classify-naive-bayes-text نادیده گرفته می‌شود. کد و مجموعه‌ی داده‌های آموزشی در آدرس <http://www.cs.cmu.edu/~tom/book.html> موجود است.

۶.۱۰.۱ نتیجه‌های تجربی

الگوریتم جدول ۶.۲ به چه میزان کارایی دارد؟ در یک آزمایش (Joachims 1996)، الگوریتم بسیار مشابهی برای دسته‌بندی مقالات خبری یوزنت^۱ بکار رفت. دسته‌بندی مقاله در این مثال اسم گروه خبری مقاله در یوزنت بود. الگوریتمی که هر مقاله را پس از دسته‌بندی در جای اصلی خود قرار می‌دهد. در این آزمایش ۲۰ گروه خبری الکترونیکی در نظر گرفته شد (که در جدول ۶.۳ نیز آمده‌اند)، سپس 1,000 مقاله از هر گروه خبری جمع شد تا تعداد نمونه‌ها به 20,000 برسد. الگوریتم ساده‌ی بیز دو سوم از این 20,000 متن به عنوان نمونه‌های آموزشی آموزش داده شد و سپس کارایی الگوریتم برای یک سوم باقیمانده ارزیابی شد. از ۲۰ گروه خبری ممکن، حداکثر مقدار دسته‌بندی درست اتفاقی ۵٪ خواهد بود، اما دقت دسته‌بندی الگوریتم ۸۹٪ اندازه‌گیری شد. الگوریتم به کار رفته در این آزمایش فقط یک تفاوت کوچک با الگوریتم جدول ۶.۲ داشت، یک زیر مجموعه از کلمات متون به عنوان واژگان^۲ در نظر گرفته شده بود. به عبارت دقیق‌تر، ۱۰۰ کلمه‌ی پرکاربرد تر واژگان در آن در نظر گرفته نشده بود (کلماتی مثل "این")، و همچنین تمامی کلماتی که کمتر از ۳ بار ظاهر شده بودند نادیده گرفته شدند. واژگان بدست آمده بدین ترتیب تقریباً 38,500 کلمه داشت.

¹ use net

² Vocabulary

نتایج چشم گیر دیگری نیز توسط دیگر روش های یادگیری آماری متون بدست آمده است. برای مثال، (Lang 1995) نسخه ای دیگر از الگوریتم ساده ی بیز را توصیف کرده و آن را در یادگیری مفهوم هدف "مقالات یوزنتی که من به آن ها علاقه دارم" به کار می برد. وی سیستم NewsWeeder را معرفی می کند، برنامه ای که به کاربران اجازه می دهد تا متون را بعد از خواند ارزیابی^۱ کنند. سیستم NewsWeeder از این ارزیابی ها به عنوان نمونه های آموزشی برای پیش بینی اینکه مقاله ای برای کاربر جالب است یا خیر استفاده می کند، پس برنامه می تواند مقالاتی که پیش بینی می کند کاربر به خواندن آن ها علاقه دارد را به وی پیشنهاد کند. (Lang 1995) آزمایشی را گزارش می کند که در آن NewsWeeder از اطلاعات یاد گرفته خود بر اساس علاقه ی کاربر، مقاله ای که بالاترین مقدار پیش بینی ارزیابی را دارد به کاربر ارائه می دهد. با ذخیره ی ۱۰٪ اول این مقالات اتوماتیک ارزیابی شده، برنامه مجموعه ای از مقالات خواهد داشت که نسبت به مجموعه ی کل مقالات سه تا چهار برابر برای کاربر جالب ترند. برای مثال، برای یک کاربر نسبت مقالاتی که "جالب"^۲ دسته بندی می کند در کل ۱۶٪ است اما در میان این مقالات ۵۹٪ توصیه ی NewsWeeder بوده.

تعداد زیاد روش های غیر بیزی آماری برای یادگیری متون متداولند، بسیاری از این روش ها بر اساس معیارهای مشابه استخراج اطلاعات هستند. (Rocchio 1971; Salton). الگوریتم های یادگیری متون دیگر در (Hearst and Hirsh 1996) آورده شده است.

۶.۱۱ شبکه های باور بیزی

همان طور که در دو قسمت قبلی نیز گفته شد، دسته بندی کننده ی ساده ی بیز از فرض اینکه احتمالات شرطی $a_1 \dots a_2$ با داشتن مقدار تابع هدف V مستقلند استفاده ی شدیدی می کند. این فرض به طور قابل توجهی میزان پیچیدگی یادگیری تابع هدف را کاهش می دهد. با این فرض، دسته بندی کننده ی ساده ی بیز دسته بندی بهینه ی بیز را خروجی می دهد. با این وجود، در بسیاری از موارد این شرط مستقل بودن به شدت محدود کننده است.

شبکه های باور بیزی^۳ توزیع احتمالات حاکم بر مجموعه ی متغیرهایی که با دسته ای از فرض استقلال احتمالات شرطی مشخص می شوند را توصیف می کنند. برخلاف دسته بندی کننده ی ساده ی بیز که فرض می کرد تمامی متغیرهای به طور شرطی با معلوم بودن فرضیه ی h مستقلند، شبکه های باور بیزی فرض های استقلال احتمالات را در زیر مجموعه های متغیرها درست می دانند. بنابراین، شبکه های باور بیزی، روشی میانی که شرطی آزادتر از فرض مستقل بودن تمامی متغیرهای دسته بندی کننده ی ساده ی بیز و محدود کننده تر از پرهیز از هر گونه شرط استقلال است، ارائه می کنند. شبکه های باور بیز یکی از موضوعات مورد توجه تحقیقات فعلی هستند، و دامنه ی وسیعی از الگوریتم ها برای یادگیری و استنتاج از آن ها ارائه شده است. در این بخش مفاهیم کلیدی و نحوه ی نمایش شبکه های باور بیزی را معرفی خواهیم کرد. اطلاعات دقیق تر در این زمینه (Pearl 1988) و (Russell and Norving 1995) و (Heckerman 1995) و (Jensen 1996) آمده است.

در کل، یک شبکه ی باور بیز توزیع های احتمال دسته ای از متغیرها را توصیف می کند. مجموعه ی دلخواهی از متغیرهای تصادفی $Y_1 \dots Y_n$ را در نظر بگیرید که هر Y_i می تواند هر یک از مقادیر مجموعه ی $V(Y_i)$ را داشته باشد. فضای توأم^۴ را مجموعه ی متغیرهای Y که از ضرب

¹ rate

² interesting

³ bayesian belief networks

⁴ joint space